

Universidad
Rey Juan Carlos

Escuela Técnica Superior
de Ingeniería Informática

Doble Grado en Educación Primaria + Matemáticas

Curso 2025-2026

Trabajo Fin de Grado

**LA GAMIFICACIÓN EN APLICACIONES
EDUCATIVAS DE MATEMÁTICAS PARA PRIMARIA:
UN ANÁLISIS EXPLORATORIO DE DATOS ABIERTOS**

Autor: Laura Iglesias García

Tutor: María Celeste Pizarro Romero

Cotutor: Raquel Hijón Neira

Agradecimientos

No podía dejar pasar esta oportunidad de agradecer a todos los que me han acompañado tanto a lo largo de todo mi camino profesional y personal. Por eso, como broche final de este trabajo y a los seis años de carrera, quiero daros las gracias.

En primer lugar, agradecerles de todo corazón a las personas que me han servido de inspiración para seguir adelante, mis abuelos. Son el mejor ejemplo no solo de abuelos sino de las personas más generosas y maravillosas que pueden existir. Me llena de un orgullo inmenso poder terminar esta etapa tan importante de mi vida a su lado. Abuelos, esto ha sido posible gracias a vosotros, ya que desde mis primeros pasos habéis estado ahí para cuidarme y apoyarme.

A mis padres, por su incansable esfuerzo para que nunca nos faltara nada. Gracias por transmitirme los valores que me han hecho ser la persona que soy, y por apoyarme y cuidarme incondicionalmente. Especialmente, gracias a ti papá porque, hasta en tu peor momento, me has ayudado. Desde pequeña me has enseñado matemáticas e informática para convertirme en la matemática que soy hoy. Y me has acompañado en cada examen para darme fuerzas hasta el último momento aunque eso supusiera levantarte de madrugada. Gracias a los dos por confiar en mí y por luchar para que yo pudiera estudiar mi carrera soñada. ¡Este título es nuestro!

A Gon, mi mano derecha y mi incondicional, gracias por tu infinita paciencia y tu cariño en esos días de máxima tensión. Gracias por celebrar mis logros, incluso más que yo, y sentirte orgulloso de todo lo que he conseguido. Gracias por tu comprensión, por tener siempre las palabras exactas y recordarme cuál era mi meta. Gracias por confiar en mí y acompañarme en todo el proyecto. Este logro también es tuyo. Te quiero.

A Diego y a Yeya, por ser mis compañeros de aventuras. Gracias por querer formar parte de mi vida y por confiar en mí. Me habéis demostrado que la distancia no es más que un número y que, quien te quiere de verdad, se hace presente de cualquier forma.

A mis tíos, gracias por recordarme lo mucho que valgo y por estar orgullosos de mí.

A mi pequeña princesa, mi Pauli. Gracias por hacerme retroceder en el tiempo y jugar con la inocencia propia de la niñez. Siempre estaré a tu lado para guiarte y acompañarte en todas tus etapas, prima.

A mi Lia y mi Duna, gracias por demostrarme lo que es el amor incondicional y, cómo sin palabras, se puede dar tanto cariño.

A ti, Celeste, gracias por tus recomendaciones, por tu paciencia y entusiasmo por el proyecto. Gracias por haberme dado este proyecto que me ha tenido enfocada tantos meses.

A todos mis profesores de matemáticas durante todas las etapas formativas. Al final me convencisteis para formar parte de este grupo de frikis a los que nos gusta pensar. Gracias por enseñarme esa parte tan desconocida de las matemáticas. Ahora soy yo la "bruja" que intenta convencer a sus alumnos de mirar a las matemáticas desde otra perspectiva.

Y, por último, a mí misma. Por ser constante y valiente en este duro viaje. He conseguido tener más seguridad en mí misma y ser más decidida. Esta carrera me ha dado muchos dolores de cabeza, pero era lo que había soñado desde que tenía 14 años. Y, por fin, lo he conseguido.

Resumen

Este trabajo tiene como objetivo central analizar cuáles son los factores que determinan el éxito comercial de las aplicaciones de matemáticas para Educación Primaria dentro de *Google Play Store*. En concreto, buscamos comprobar si la presencia de elementos de gamificación está relacionada con una mayor popularidad. Desde el primer momento, es preciso que señale que el éxito comercial medido bajo esta métrica no debe confundirse con la calidad pedagógica o el impacto sobre el aprendizaje. Por ello, identificamos esta barrera como una limitación estructural del diseño ya que la evaluación de estos aspectos queda fuera del alcance del estudio.

Desde el punto de vista metodológico, partimos de un repositorio público de *Google Play Store* del que delimitamos una población objetivo de 4.218 aplicaciones empleando técnicas de depuración y filtrado semántico. Para desglosar este proceso con total transparencia, a lo largo de las siguientes subsecciones detallaremos la estrategia de muestreo estratificado, el protocolo manual de codificación de variables y, por último, la especificación del modelo estadístico evaluado. Sobre esta población aplicamos un muestreo aleatorio estratificado con afijación uniforme ($n = 200$, con 50 observaciones por estrato). Como los estratos se definieron a través de los cuartiles poblacionales de la variable de popularidad, cada uno contiene por construcción aproximadamente el 25 % de la población. Esto indica que la afijación uniforme coincide en la práctica con la afijación proporcional ($w_h \approx 21,09$ para todo h , en cuanto a la variación entre pesos: $< 0,1\%$). Como consecuencia, los estimadores no requieren corrección por pesos de diseño y, por tanto, son aplicables directamente a la población objetivo. Las variables de gamificación se codificaron manualmente mediante inspección heurística con validación inter-jueces ($\bar{\kappa} = 0,831$). Para analizar los datos se ha utilizado un modelo de regresión lineal múltiple (estimado por mínimos cuadrados ordinarios) en el programa estadístico R. Es necesario señalar una limitación importante del método ya que *Google Play* no proporciona cifras exactas de descargas. Por eso, se tuvieron en cuenta sus rangos estimados como variable dependiente.

Estos resultados nos muestran asociaciones estadísticas, no relaciones de causalidad. La mayoría de las mecánicas analizadas (niveles, *rankings* y avatares) no presentan una asociación estadísticamente significativa con el volumen de descargas. Únicamente los sistemas de recompensa muestran una asociación positiva

y significativa ($\hat{\beta} = 0,986$; $p = 0,008$), equivalente a un factor de descarga estimado 9,7 veces mayor respecto a aplicaciones sin esta mecánica. Cuatro análisis complementarios confirman la solidez de este hallazgo: reestimación sin observaciones influyentes ($\hat{\beta} = 1,566$, $p < 0,001$), bootstrapping no paramétrico con 1.000 remuestras (IC_{95%} [0,17; 1,64]), test exacto de Fisher sobre la distribución por estratos ($p = 0,002$) y análisis de sensibilidad del estimador bayesiano frente a seis valores del umbral de regularización m_0 . El *feedback* inmediato, pese a ser la mecánica más prevalente en la muestra, presenta una asociación negativa con las descargas, lo que sugiere que su presencia caracteriza aplicaciones de nicho con audiencias reducidas más que aplicaciones de amplio alcance comercial. De todos los factores, la forma de rentabilizar las aplicaciones es la más influyente en el sentido de que las aplicaciones con compras integradas cuentan con un volumen de descargas 5,4 veces mayor aproximadamente, tal y como ya señalaban otros estudios sobre modelos *freemium*. Por otro lado, los datos sugieren que la gamificación básica ha dejado de ser un gancho que consigue usuarios y ha pasado a ser simplemente lo mínimo que se espera del diseño. La limitación más relevante del estudio es que las métricas de las tiendas de aplicaciones no nos aportan nada sobre el aprendizaje real de los usuarios.

Palabras clave:

- Gamificación educativa
- Aplicaciones educativas para matemáticas
- Regresión Lineal Múltiple
- Análisis de Datos con R
- Análisis de sensibilidad y robustez
- Modelo *Freemium*

Índice de contenidos

Índice de tablas	XIII
Índice de figuras	XV
Índice de códigos	XVII
1. Introducción	1
1.1. El reto matemático en la educación primaria y el papel de las TIC	1
1.2. La gamificación como estrategia de diseño en aplicaciones educativas	2
1.3. Enfoque del presente estudio	3
2. Objetivos	5
2.1. Objetivo General	5
2.2. Objetivos Específicos	6
2.3. Justificación del Enfoque Metodológico	7
3. Metodología	8
3.1. Diseño de la Investigación y Fuente de Datos	10
3.1.1. Origen de los Datos	10
3.2. Algoritmo de Depuración y Definición de la Población	11
3.2.1. Preprocesamiento y Limpieza (<i>Data Cleaning</i>)	11
3.2.2. Filtro Semántico y Categorización	12
3.2.3. Cuantificación de la Población Objetivo	14
3.3. Estrategia de Muestreo y Estratificación	14
3.3.1. Justificación de la Variable de Estratificación: Popularidad Logarítmica	14
3.3.2. Diseño del Muestreo Estratificado	15
3.3.3. Determinación y Validación del Tamaño Muestral	15
3.4. Implementación Técnica y Construcción de la Matriz de Diseño	16
3.4.1. Entorno Computacional y Paquetes de Software	18
3.5. Operacionalización de Variables	19
3.5.1. Vector de Gamificación (Variables de Interés)	19
3.5.2. Variables de Control	20

3.5.3.	Protocolo de Codificación y Fiabilidad Inter-jueces	21
3.5.4.	Índice Compuesto de Gamificación (IGam)	22
3.6.	Criterios de Selección y Exclusión de Variables	22
3.7.	Especificación del Modelo Estadístico	24
3.7.1.	Modelo I: Vector de Variables Individuales	24
3.7.2.	Modelo II: Índice Compuesto de Gamificación	24
3.7.3.	Interpretación de los Coeficientes (Modelo <i>Log-Level</i>)	25
3.8.	Estrategia de Análisis y Diagnóstico	25
4.	Análisis de Resultados	27
4.1.	Caracterización de la Población y Validación de la Muestra	27
4.1.1.	Proceso de Reducción de Datos	27
4.1.2.	Fiabilidad Inter-jueces de la Codificación	28
4.2.	Estadísticos Descriptivos y Caracterización de la Muestra	29
4.2.1.	Heterogeneidad en la Popularidad (Y)	29
4.2.2.	Patrones de Adopción de Gamificación	29
4.2.3.	Distribución del Índice IGam	32
4.2.4.	Asimetría en Precio y Calidad Percibida	33
4.3.	Análisis de Correlaciones	34
4.4.	Estimación del Modelo de Regresión Lineal Múltiple	35
4.4.1.	Modelo I: Resultados con Errores Robustos HC3	35
4.4.2.	Bondad de Ajuste Global	35
4.4.3.	Interpretación de los Coeficientes Significativos	36
4.4.4.	No Significatividad de Niveles, Ranking y Avatares	38
4.4.5.	Modelo II: Índice Compuesto <i>IGam</i>	39
4.4.6.	Análisis de Sensibilidad: Robustez del Coeficiente de Re- compensas	40
4.5.	Diagnóstico del Modelo	41
4.5.1.	Multicolinealidad (VIF)	41
4.5.2.	Heterocedasticidad	42
4.5.3.	Normalidad de los Residuos	42
4.5.4.	Observaciones Influyentes	43
4.5.5.	Sensibilidad del Estimador Bayesiano: Elección de m_0	43
5.	Conclusiones y Trabajos Futuros	46
5.1.	Discusión de los Resultados	46
5.1.1.	La Paradoja de la Gamificación: entre el Estándar y el Di- ferenciador	46
5.1.2.	El Efecto Negativo del Feedback: una Interpretación Con- textual	48
5.1.3.	El Triunfo del Modelo Freemium	48
5.1.4.	Rating Ajustado: la Brecha entre Calidad y Popularidad	49

5.2. Conclusiones	49
5.3. Implicaciones Prácticas	50
5.3.1. Para Desarrolladores de Aplicaciones Educativas	50
5.3.2. Para la Comunidad Educativa	51
5.4. Limitaciones del Estudio	51
5.5. Líneas de Investigación Futura	53
5.5.1. Del Análisis Binario a la Intensidad Gamificada	53
5.5.2. Automatización mediante Procesamiento de Lenguaje Na- tural	54
5.5.3. Estudios Longitudinales con Datos de Panel	54
5.5.4. Métricas de Aprendizaje y Retención	54
Bibliografía	54
Apéndices	60
A. Código R Utilizado en el Análisis	62

Índice de tablas

3.1. Diccionario de variables del <i>dataset</i> original (Ω_{raw}).	11
3.2. Paquetes de R empleados en el análisis.	19
4.1. Embudo de selección de la población objetivo (Ω_{pop}) y distribución por estratos.	28
4.2. Coeficientes kappa de Cohen por variable de gamificación (tras reconciliación conservadora, $n_{\kappa} = 30$).	29
4.3. Estadísticos descriptivos de las variables del modelo ($n = 200$). . .	30
4.4. Prevalencia de mecánicas de gamificación e IAP por estrato de popularidad (%).	30
4.5. Tests de independencia Estrato $\times$ Mecánica de gamificación ($n = 200$).	31
4.6. Distribución del índice compuesto de gamificación (<i>IGam</i>).	33
4.7. Resultados de la regresión MCO con errores robustos HC3 (variable dependiente: $\log_{10}$ descargas).	36
4.8. Resultados del Modelo II (variable dep.: $\log_{10}$ descargas; predictor: <i>IGam</i>).	39
4.9. Resumen de los análisis de sensibilidad del coeficiente de Recomendaciones.	41
4.10. Diagnóstico de colinealidad (VIF), Modelo I.	42
4.11. Análisis de sensibilidad del Modelo I según el umbral de regularización m_0 del estimador bayesiano de calidad percibida. Variable dependiente: $\log_{10}$ descargas. Errores robustos HC3.	44

Índice de figuras

3.1. Diagrama de flujo del proceso metodológico. Elaboración propia. .	9
4.1. Distribución del índice compuesto de gamificación (<i>IGam</i>) en la muestra ($n = 200$).	33
4.2. Matriz de correlaciones de Pearson ($n = 200$). Los tonos azules coeficientes positivos y los rojos indican valores negativos; la intensidad del color es directamente proporcional a la magnitud de la correlación.	34
4.3. Gráfico Q-Q de los residuos estandarizados (Modelo I).	43
4.4. Distancia de Cook por índice de observación. Línea discontinua: umbral $4/n = 0,020$	44

Índice de códigos

A.1. Carga de paquetes	62
A.2. Verificación de tamaños poblacionales por estrato	62
A.3. Validacion empirica del filtro semantico K	63
A.4. Kappa de Cohen	64
A.5. Carga, transformación e imputación de datos	65
A.6. Validación del umbral de regularización m_0	65
A.7. Estadísticos descriptivos y prevalencia por estrato	65
A.8. Tests de independencia Mecanica por Estrato	66
A.9. Matriz de correlaciones de Pearson	67
A.10. Estimación del Modelo I (MCO con errores robustos HC3)	67
A.11. Test F de restricciones lineales (Modelo I vs. Modelo II)	67
A.12. Estimación del Modelo II (índice compuesto IGam)	67
A.13. Diagnóstico del Modelo I: VIF, heterocedasticidad, normalidad y observaciones influyentes	68
A.14. Análisis de robustez del coeficiente de Recompensas	68
A.15. Test de equivalencia TOST para Niveles y Ranking	69
A.16. Sensibilidad del estimador bayesiano segun m_0	70

1

Introducción

1.1. El reto matemático en la educación primaria y el papel de las TIC

La revolución tecnológica de las últimas décadas ha transformado profundamente el panorama educativo, abriendo nuevas vías para enseñar y aprender. Las Tecnologías de la Información y la Comunicación (TIC) se han consolidado como recursos clave para promover metodologías más activas y adaptadas a las necesidades del alumnado (Ramas et al., 2015; Prendes et al., 2012). A pesar de este avance tecnológico, existe una preocupación creciente por el rendimiento académico de las matemáticas. Los datos del informe TIMSS (*Trends in International Mathematics and Science Study*) revelan un descenso continuado en el rendimiento del alumnado de Primaria en dicha materia. En el último informe se registró una media de 498, ligeramente inferior a los 502 puntos alcanzados en la pasada edición (IEA, 2020). Es más, seguimos estando muy por debajo del promedio de la OCDE (525) y de la Unión Europea (514) (IEA, 2024).

Esta dificultad no es reciente. La mayoría de los investigadores educativos llevan décadas señalando que la enseñanza de conceptos abstractos en el área de matemáticas exige enfoques pedagógicos que fomenten la comprensión activa y eliminen la memorización mecánica (Freudenthal, 1991; Godino et al., 2003). Por ello, la normativa vigente (Jefatura del Estado, 2020) y los organismos internacionales, como el *National Council of Teachers of Mathematics* (NCTM, 2000), coinciden en elevar la importancia de vincular los contenidos matemáticos con situaciones cotidianas del alumnado. A este reto se le añade una realidad alar-

manente según se recoge en IEA (2024): el 37,8 % del alumnado español de 4.º de Primaria muestra un nivel bajo o muy bajo en competencia matemática. Este dato revela una situación de desventaja frente al 27,0 % del promedio de la OCDE y el 30,4 % del total de la UE, lo que hace indispensable explorar nuevos métodos que despierten la motivación y las ganas de descubrir desde las primeras etapas de aprendizaje de un alumno (Mora, 2014).

En este escenario, el aprendizaje con dispositivos inteligentes (*mobile learning*) surge como una alternativa accesible y extendida. Los datos oficiales del Instituto Nacional de Estadística (INE) para 2025 mostraron que el 96,5 % de los menores españoles (10 - 15 años) navegaba por Internet, el 96,9 % utilizaba ordenador y el 67,9 % disponía de un teléfono móvil propio (Instituto Nacional de Estadística, 2025). Esto es ideal para incorporar aplicaciones como recurso de apoyo al aprendizaje matemático (Suárez Caballero, 2023; Tolentino-Veliz et al., 2023). No obstante, la calidad pedagógica de estas herramientas es muy desigual ya que diversas investigaciones sobre el diseño de aplicaciones infantiles señalan que la mayoría no respeta los ritmos de desarrollo cognitivo de los niños (Crescenzi-Lanna and Grané-Oró, 2016; Hirsh-Pasek et al., 2015). Este hecho dificulta la labor de las familias y de los docentes al intentar seleccionar un recurso adecuado. Por lo tanto, saber qué características logran que una *app* triunfe en el sentido comercial es necesario para orientarse en el mercado, siempre que tengamos en cuenta que el éxito comercial y el valor pedagógico rara vez van unidos.

1.2. La gamificación como estrategia de diseño en aplicaciones educativas

Incorporar mecánicas de juego o, mejor nombrado, el fenómeno conocido como gamificación, es una de las respuestas más extendidas en el diseño de aplicaciones educativas. Este concepto se refiere a la aplicación de elementos, dinámicas y estéticas propias del juego en contextos no lúdicos con el objetivo de aumentar la motivación y el compromiso del usuario (Escribano, 2016; Ortiz et al., 2018; Werbach and Hunter, 2012). En el aprendizaje de las matemáticas, tolerar el error y recibir un refuerzo positivo es clave (Mora, 2014; Godino et al., 2003). Por este motivo, la gamificación se consolida como una estrategia de diseño relevante (Suárez Caballero, 2023).

Desde el punto de vista de la didáctica, integrar el juego cobra sentido en cuanto a que fomenta un aprendizaje significativo (Bruner, 1961), normaliza el error como parte del proceso (Godino et al., 2003), y ofrece respuestas inmediatas que mantienen la motivación del estudiante (Ryan and Deci, 2000; Hattie and Timperley, 2007). Si bien algunos estudios indican que los entornos digitales lúdicos aumentan la participación (Tolentino-Veliz et al., 2023), aunque la mayor parte de esta evidencia proviene de muestras reducidas o de diseños con limitada

validez externa (Hamari et al., 2014), lo cual no permite confirmar un aprendizaje matemático real. Es importante subrayar, además, que la adopción comercial de una aplicación, medida por sus descargas, y su eficacia pedagógica son dimensiones distintas que no pueden equipararse sin evidencia específica. Esto quiere decir que una aplicación puede ser muy descargada por razones comerciales sin que ello implique calidad didáctica, y viceversa (Crescenzi-Lanna and Grané-Oró, 2016).

Para identificar las mecánicas de gamificación, adoptamos la taxonomía PBL (*Points, Badges, Leaderboards*) de Werbach and Hunter (2012) y el marco MDA (*Mechanics–Dynamics–Aesthetics*) de Hunicke et al. (2004), que nos permite implantar cinco elementos discretos y observables: sistemas de niveles, recompensas, tablas de clasificación (*rankings*), avatares y retroalimentación inmediata (*feedback*). La evidencia empírica cuantitativa sobre cuáles de ellas se asocian con una mayor adopción comercial de las aplicaciones educativas sigue siendo escasa a pesar de su relevancia teórica (Hamari et al., 2014). La mayor parte de los estudios disponibles no aprovecha la escala de los datos públicos que se encuentran en *Google Play Store* o *App Store* ni controla estadísticamente los factores de monetización o la calidad percibida.

1.3. Enfoque del presente estudio

Este Trabajo se centra en la brecha metodológica descrita haciendo uso del análisis estadístico de datos secundarios procedentes de *Google Play Store*, obtenidos a través del repositorio público disponible en *Kaggle* (gauthamp10, 2021). A partir de una población depurada de 4.218 aplicaciones educativas de matemáticas, cuya estratificación verificamos empíricamente sobre el repositorio original (véase Código A.2), se extrae una muestra estratificada ($n = 200$) sobre la que codificamos manualmente las variables de gamificación y estimamos un modelo de regresión lineal múltiple por Mínimos Cuadrados Ordinarios (MCO) en el entorno estadístico R.

El objetivo central es analizar si la presencia de mecánicas de gamificación (niveles, recompensas, *rankings*, avatares y *feedback*) se asocia con una mayor popularidad comercial, medida a través del volumen estimado de descargas. El diseño es de carácter observacional y transversal: los resultados describen asociaciones estadísticas entre variables y no permiten establecer relaciones de causalidad (Hernández-Sampieri et al., 2014). El éxito comercial medido mediante las descargas no debe equipararse con el impacto pedagógico real: los datos disponibles públicamente solo permiten aproximarse al primero, mientras que la medición del aprendizaje efectivo del alumnado requeriría datos longitudinales de uso, tiempos de sesión, tasas de retención, resultados en evaluaciones estandarizadas, que no son accesibles a través de repositorios públicos. Esta imposibilidad constituye la limitación más relevante del estudio desde una perspectiva educativa.

Con estos resultados se pretende ofrecer un marco analítico basado en evidencia que sirva de referencia para futuras investigaciones que combinen métricas comerciales con indicadores de calidad pedagógica, y que contribuya a orientar, con mayor rigor empírico, el debate sobre el papel de la gamificación en las aplicaciones educativas de matemáticas.

2

Objetivos

Plantear objetivos claros y verificables es fundamental en cualquier investigación científica, pues ayuda a tomar decisiones metodológicas adecuadas y garantiza la coherencia de todo el estudio (Hernández-Sampieri et al., 2014). En educación, esta claridad es imprescindible, sobre todo cuando se investigan realidades que combinan pedagogía, tecnología y ventas (Prendes et al., 2012).

Partiendo de esta base, este proyecto une los principios de la estadística aplicada con la tecnología educativa. Por ello, el propósito principal es analizar datos públicos para averiguar si incluir elementos de gamificación en las aplicaciones de matemáticas para Primaria se traduce realmente en una mayor popularidad comercial, tomando como referencia su volumen de descargas.

2.1. Objetivo General

Principalmente, nos centraremos en analizar estadísticamente la asociación entre la presencia de elementos de gamificación y el éxito comercial (a través del volumen estimado de descargas) de las aplicaciones educativas de matemáticas para Educación Primaria disponibles en *Google Play Store*, mediante un modelo de regresión lineal múltiple estimado por Mínimos Cuadrados Ordinarios (MCO) en el entorno estadístico R.

2.2. Objetivos Específicos

1. **Construir la muestra analítica:** Seleccionar y filtrar una muestra representativa de aplicaciones educativas de matemáticas para Primaria. Para ello, partiremos del repositorio público de *Google Play Store* disponible en *Kaggle* (gauthamp10, 2021), aplicando una serie de criterios de búsqueda semántica y de calidad de los datos.
2. **Codificar las variables de gamificación:** Comprobar manualmente si cada aplicación incluye o no elementos clave de gamificación (niveles, sistemas de recompensa, tablas de clasificación (*rankings*), avatares y retroalimentación inmediata *feedback*). Además, se garantizará la fiabilidad de esta revisión manual utilizando el coeficiente kappa de Cohen (Cohen, 1960).
3. **Depurar y preparar la base de datos:** Realizar un proceso de limpieza y transformación de los datos riguroso, que incluya el tratamiento de valores atípicos (*outliers*), la recodificación de variables categóricas como vectores binarios, la transformación logarítmica de la variable dependiente y el cálculo del estimador bayesiano sobre la calidad percibida, con el fin de garantizar la consistencia de la muestra para su posterior modelización.
4. **Realizar el análisis exploratorio y descriptivo:** Aplicar las técnicas de estadística descriptiva necesarias, los *tests* de independencia y un análisis de correlación en R para estudiar cómo se distribuyen las variables, contrastar si la adopción de las mecánicas de gamificación es homogénea entre estratos de popularidad, detectar posibles relaciones entre las métricas de popularidad comercial y los elementos de gamificación, e identificar patrones estructurales en los datos previos a la estimación del modelo.
5. **Estimar y comparar los modelos de regresión:** Ajustar dos especificaciones de regresión lineal múltiple por MCO: el Modelo I, con el vector de variables individuales de gamificación, y el Modelo II, con el índice compuesto IGam. Ambos modelos incluyen variables de control por precio, calidad percibida y el modelo de monetización. Verificar los supuestos mediante pruebas de diagnóstico estándar (multicolinealidad, heterocedasticidad y normalidad de residuos) y comparar la bondad de ajuste mediante el R^2 ajustado. Evaluar la robustez de los coeficientes significativos mediante análisis de sensibilidad: reestimación sin observaciones influyentes, *bootstrapping* no paramétrico y análisis de sensibilidad del estimador bayesiano de calidad percibida frente a distintos valores del umbral de regularización m_0 .
6. **Interpretar los resultados y extraer implicaciones prácticas:** Discutir los hallazgos en clave de diseño de aplicaciones educativas, poniendo en diálogo los patrones comerciales detectados con los principios de la didáctica de las matemáticas (Godino et al., 2003; NCTM, 2000; Hattie and

Timperley, 2007), sin inferir relaciones causales ni equivalencias entre popularidad comercial e impacto pedagógico. Se identificarán asimismo las limitaciones derivadas del carácter observacional del diseño y de la imposibilidad de medir el aprendizaje efectivo del alumnado a partir de las fuentes disponibles, que constituye la limitación principal del estudio.

2.3. Justificación del Enfoque Metodológico

Este trabajo nace de la necesidad de complementar la abundante literatura cualitativa sobre gamificación educativa con un análisis cuantitativo sistemático y reproducible. Frente a los estudios basados en encuestas o experimentos de laboratorio con muestras reducidas (Hamari et al., 2014), el uso de datos secundarios de acceso público permite detectar patrones robustos sin los costes asociados a la recogida de datos primarios (Vartanian, 2010).

Se eligió la regresión lineal múltiple como método de análisis ya que permite calcular el peso exacto de cada variable de gamificación sobre el éxito de la aplicación, aislando el efecto de otros factores como el precio, la calidad percibida o el modelo de negocio. Este enfoque ofrece la opción de comparar dos modelos distintos (usar las variables por separado o agruparlas en un índice compuesto) para comprobar si se pierde información relevante cuando se simplifican los datos.

Resulta fundamental aclarar el alcance de este proyecto porque se centra exclusivamente en el éxito comercial, medido a través del número estimado de descargas. Por lo que analizar si esta popularidad se relaciona con el aprendizaje real del alumnado, constituye una investigación completamente diferente que requeriría métricas privadas como el tiempo de uso o la retención de los usuarios. Esta limitación marca la frontera del trabajo, aunque, por otra parte, abre una vía de estudio futuro de valor relevante para la comunidad educativa.

3

Metodología

En este capítulo se describen los pasos seguidos para la construcción de la muestra de análisis, la limpieza de la base de datos y la definición de las variables escogidas. La metodología escogida combina la estadística inferencial con el análisis de datos secundarios para asegurar que los cálculos informáticos se puedan reproducir y que las conclusiones estadísticas sean válidas (Peng, 2011).

Se trata de un estudio de carácter **cuantitativo, observacional y transversal**. Dado que no ha existido experimento alguno ni se ha contado con un grupo de control, los resultados mostrarán asociaciones estadísticas entre variables, sin que sea posible interpretar relaciones de causalidad (Hernández-Sampieri et al., 2014). Esta limitación condiciona la interpretación de todos los coeficientes estimados y se retoma en el Capítulo 5.

El flujo de trabajo cuenta con seis fases secuenciales, tal y como se ilustra en la Figura 3.1: (1) adquisición de datos, (2) preprocesamiento y depuración, (3) definición poblacional, (4) muestreo estratificado, (5) operacionalización y codificación manual de variables, y (6) especificación y diagnóstico del modelo. La finalidad de esta investigación no es más que cuantificar la asociación entre la presencia de elementos de gamificación ($\mathbf{X}$) y el éxito comercial de las aplicaciones educativas de matemáticas (variable dependiente Y), medida a través del volumen estimado de descargas.




Figura 3.1: Diagrama de flujo del proceso metodológico. Elaboración propia.

3.1. Diseño de la Investigación y Fuente de Datos

Se trata de un estudio cuantitativo de carácter correlacional basado en el análisis de datos secundarios. Como señala [Vartanian \(2010\)](#), este enfoque resulta eficiente en cuanto a la cantidad de información existente. Así, permite detectar patrones claros sin tener que asumir los costes asociados a la recolección de datos desde cero.

3.1.1. Origen de los Datos

El conjunto de datos original, denotado Ω_{raw} , proviene del repositorio público *Google Play Store Apps* disponible en la plataforma *Kaggle* ([gauthamp10, 2021](#)). Esta base de datos contiene $N \approx 2,3 \times 10^6$ registros que reflejan el estado del mercado de aplicaciones en 2021. El corte temporal se eligió por ser el conjunto de datos públicos con mayor completitud de metadatos disponible (métricas de desarrollo, categorías, fechas y rangos de instalación), aunque conviene señalar que el mercado de aplicaciones educativas ha podido experimentar cambios desde entonces, lo que constituye una limitación temporal inherente al diseño (véase Sección 5.4).

La Tabla 3.1 detalla las variables originales. Cabe señalar que la variable `Maximum Installs` no refleja un número de descargas exacto, sino el límite superior del rango estimado que publica *Google Play* (p.ej., una aplicación con “1.000.000+” instalaciones puede moverse entre uno y 4,99 millones). Esta imprecisión constituye también una limitación estructural en el estudio que se retoma en la Sección 5.4.

Tabla 3.1: Diccionario de variables del *dataset* original (Ω_{raw}).

Variable	Dominio	Descripción
App Name	$\mathbb{S}$	Identificador nominal de la aplicación.
App Id	$\mathbb{S}$	Identificador único de la <i>app</i> .
Category	$\mathbb{S}$	Categoría comercial asignada por <i>Google Play</i> .
Rating	$\mathbb{R} \in [0, 5]$	Valoración media otorgada por los usuarios.
Rating Count	$\mathbb{N}$	Número total de valoraciones recibidas.
Installs	$\mathbb{S}$	Rango textual de instalaciones (p. ej., “10.000+”).
Minimum Installs	$\mathbb{N}$	Límite inferior del rango estimado de descargas.
Maximum Installs	$\mathbb{N}$	Límite superior del rango estimado de descargas.*
Free	$\mathbb{B}$	Indica si la <i>app</i> es gratuita o de pago.
Price	$\mathbb{R}_{\geq 0}$	Coste de adquisición en moneda local.
Currency	$\mathbb{S}$	Moneda del precio (generalmente USD).
Size	$\mathbb{S}$	Tamaño del archivo (heterogéneo: “12M”, “varies”).
Minimum Android	$\mathbb{S}$	Versión mínima de Android requerida.
Developer Id	$\mathbb{S}$	Identificador del desarrollador.
Developer Website	$\mathbb{S}$	Página web oficial del desarrollador.
Developer Email	$\mathbb{S}$	Correo electrónico de contacto.
Released	Date	Fecha de publicación en la tienda.
Last Updated	Date	Fecha de la última actualización.
Content Rating	$\mathbb{S}$	Clasificación de contenido por edad (PEGI).
Privacy Policy	$\mathbb{S}$	Enlace a la política de privacidad.
Ad Supported	$\mathbb{B}$	Indica si la <i>app</i> incluye publicidad.
In App Purchases	$\mathbb{B}$	Indica si contiene compras integradas (IAP).
Editors Choice	$\mathbb{B}$	Señala si fue destacada editorialmente por Google.
Scraped Time	Timestamp	Fecha y hora de la extracción del registro.

Nota: $\mathbb{S}$: cadena de caracteres; $\mathbb{B}$: booleano; $\mathbb{N}$: número natural; $\mathbb{R}$: número real. *Maximum Installs es un

rango estimado, no una cifra exacta (véase texto principal).

3.2. Algoritmo de Depuración y Definición de la Población

Sea Ω_{raw} el espacio muestral inicial descrito en la sección anterior. El proceso de depuración tiene como objetivo definir un subconjunto $\Omega_{pop} \subset \Omega_{raw}$ que constituya la población objetivo válida para el análisis inferencial. Este procedimiento se realizó en R (R Core Team, 2023) haciendo uso de una secuencia de filtros deductivos que garantizan la reproducibilidad computacional del proceso (Peng, 2011).

3.2.1. Preprocesamiento y Limpieza (*Data Cleaning*)

Con el fin de asegurar la calidad y la coherencia de los datos, siguiendo las directrices del proceso KDD (Fayyad et al., 1996), se aplicaron las siguientes

transformaciones $T : \Omega \rightarrow \Omega'$ en las variables. El código empleado se recoge en el Anexo A.5.

1. **Tipificación y estandarización:** Conversión explícita de los formatos de datos (texto a fechas o a enteros) para permitir el análisis estadístico posterior.
2. **Tratamiento de valores nulos:** Eliminación de los registros i tales que $\text{AppName}_i = \emptyset$ o $\text{App Id}_i = \emptyset$, al no contar con los datos mínimos para su identificación y análisis.
3. **Filtro de interacción real:** Restricción $\text{Rating Count}_i > 0$ para descartar aplicaciones sin ninguna valoración registrada, que no presentan interacción real de usuarios y sesgarían el análisis de popularidad (Fayyad et al., 1996).
4. **Unicidad de la observación:** Eliminación de registros duplicados utilizando App Id como clave primaria para que así cada aplicación aparezca una única vez en la muestra.
5. **Coherencia numérica:** Conversión de Maximum Installs a tipo numérico y eliminación de los registros con valor nulo o igual a cero.

3.2.2. Filtro Semántico y Categorización

Al no existir una etiqueta específica para “Matemáticas” dentro de las categorías *Education* o *Educational* de *Google Play*, se construyó una función indicadora I_{math} basada en el análisis semántico del nombre de cada aplicación.

Sea S_i el conjunto de *tokens* (palabras normalizadas a minúsculas) del nombre de la aplicación i . Se define la variable binaria:

$$\text{EsMatematica}_i = \begin{cases} 1 & \text{si } S_i \cap K \neq \emptyset \\ 0 & \text{en otro caso} \end{cases} \quad (3.1)$$

donde K es el conjunto finito de palabras clave del dominio, seleccionadas por su alta frecuencia de aparición en aplicaciones educativas de referencia:

$$K = \{\text{“math”, “matem”, “subtract”, “multiply”, “division”, “geometry”, “algebra”, “calculus”}\} \quad (3.2)$$

Este enfoque heurístico prioriza la *precisión* (minimización de falsos positivos) sobre la *exhaustividad*: aunque puede omitir aplicaciones cuyos títulos no sean

descriptivos del contenido matemático, garantiza que el corpus final Ω_{pop} sea conceptualmente uniforme y libre de ruido semántico.

En este sentido, la selección de $\mathcal{K}$ da prioridad a los términos en inglés porque este es el idioma oficial en el diseño y etiquetado de aplicaciones en *Google Play Store*, independientemente del mercado de destino. El *token matem* se incluye como extensión para capturar aplicaciones nombradas en castellano.

Para validar esta elección de $\mathcal{K}$ realizamos una comparación con un conjunto ampliado al que denominamos $\mathcal{K}^+$. En él incorporamos términos adicionales del dominio, como:

- **Términos en inglés:** arithmetic, fraction, number, addition, times table y count.
- **Términos en castellano:** suma, resta, multiplicar y fraccion.

Este conjunto ampliado consiguió capturar 5.799 aplicaciones frente a las 4.218 de $\mathcal{K}$, incorporando, por tanto, 1.581 registros adicionales. El análisis sistemático de estos registros reveló que el 85 % de las incorporaciones adicionales estaba impulsado por dos términos de alta ambigüedad semántica: *number* (652 apps) y *count* (689 apps), que capturan aplicaciones ajenas al dominio matemático curricular, tales como juegos de cocina, aplicaciones de geografía y juguetes digitales para bebés. La inspección manual de las 50 aplicaciones con mayor volumen de descargas entre las nuevas incorporaciones confirma que únicamente el 50 % son inequívocamente matemáticas, el 32 % son fronterizas (aprenden a contar pero carecen de contenido curricular) y el 18 % son falsos positivos sin relación con las matemáticas. Los términos ausentes en $\mathcal{K}$ (*fraction*, *arithmetic*, *times table*, *suma*, *resta*, *multiplicar*) incluyen 270 aplicaciones adicionales aproximadamente. Esto constituye un *recall gap* estimado del 6,4 % respecto a Ω_{pop} . Este porcentaje se considera asumible porque es inferior al umbral del 10 % habitualmente aceptado en estudios de recuperación de información con prioridad de precisión (Manning et al., 2008), las aplicaciones no capturadas corresponden mayoritariamente a títulos no descriptivos del contenido matemático o con elementos ambiguos y su inclusión introduciría un 18 % de falsos positivos en las aplicaciones de mayor popularidad. Estos hechos comprometen la homogeneidad de la muestra (Fayyad et al., 1996). Por otro lado, el código de esta validación se recoge en el Anexo A.3.

La población objetivo final queda definida formalmente como:

$$\Omega_{\text{pop}} = \left\{ i \in \Omega \mid \text{Category}_i \in \{ \text{“Education”}, \text{“Educational”} \} \right. \\ \left. \wedge \text{EsMatematica}_i = 1 \right\} \quad (3.3)$$

3.2.3. Cuantificación de la Población Objetivo

La aplicación secuencial de los criterios anteriores delimitó una población objetivo de $N_{\text{pop}} = 4.218$ aplicaciones. Los resultados cuantitativos del proceso de reducción de datos DM (*data funnel*) se presentan en la Tabla 4.1 del Capítulo 4. Este marco poblacional depurado constituye la base sobre la cual se define la estrategia de muestreo estratificado que se detalla en la sección siguiente.

3.3. Estrategia de Muestreo y Estratificación

Como detectar variables de gamificación requiere inspección directa de la interfaz de cada aplicación, el análisis no es automatizable a partir de los datos disponibles. Esta restricción operativa hace inviable el análisis al completo del conjunto Ω_{pop} . En consecuencia, se diseñó una estrategia de muestreo que garantiza la representación equilibrada de todos los segmentos de popularidad.

3.3.1. Justificación de la Variable de Estratificación: Popularidad Logarítmica

La distribución del número de descargas en mercados de aplicaciones móviles no sigue una distribución normal, sino una ley de potencia ($P(x) \propto x^{-\alpha}$), caracterizada por una fuerte asimetría positiva y una cola larga (Clauset et al., 2009). Por lo que usar directamente la variable `Maximum Installs` generaría dos problemas graves a la hora de estimar el modelo:

1. **Sesgo de escala:** la varianza de las aplicaciones más populares eclipsaría la de las aplicaciones minoritarias, alterando los resultados de los estimadores MCO.
2. **Heterocedasticidad:** Debido a que no se mantiene una varianza constante en los errores, los contrastes estadísticos perderían su fiabilidad.

Para solucionar estos efectos y estabilizar la varianza, se aplicó la transformación logarítmica recomendada por Wooldridge (2012) para analizar equitativa y proporcionalmente los datos:

$$Y_i = \log_{10}(\text{Maximum Installs}_i + 1) \quad (3.4)$$

El término $+1$ evita la indeterminación en el origen ($\log 0$). La variable resultante Y_i presenta una distribución aproximadamente normal, idónea tanto como

variable de estratificación como variable dependiente del modelo. La imprecisión inherente a `Maximum Installs` (que es un rango estimado, no una cifra exacta) introduce incertidumbre en Y_i que no puede corregirse con los datos disponibles y se identifica como limitación metodológica (Sección 5.4).

3.3.2. Diseño del Muestreo Estratificado

Se optó por un muestreo aleatorio estratificado frente al muestreo aleatorio simple (MAS). En una distribución de Pareto, el MAS seleccionaría mayoritariamente aplicaciones de la cola (bajas descargas), dejando infrarrepresentados los casos de mayor éxito comercial. La estratificación garantiza la presencia equilibrada de todos los segmentos.

La población se dividió en $k = 4$ estratos disjuntos H_k , definidos por los cuartiles poblacionales de Y_i calculados sobre Ω_{pop} :

- **Estrato 1 (Baja):** $Y_i < Q_{0,25} = 2,961$ (≈ 915 descargas).
- **Estrato 2 (Media):** $Q_{0,25} \leq Y_i < Q_{0,50} = 3,694$ (≈ 4.942 descargas).
- **Estrato 3 (Media-Alta):** $Q_{0,50} \leq Y_i < Q_{0,75} = 4,470$ (≈ 29.507 descargas).
- **Estrato 4 (Alta):** $Y_i \geq Q_{0,75} = 4,470$ (más de 29.507 descargas).

Los cuartiles se calcularon sobre la distribución completa de Ω_{pop} en R con semilla fija `set.seed(42)`, lo que garantiza la reproducibilidad exacta del muestreo (Peng, 2011).

3.3.3. Determinación y Validación del Tamaño Muestral

Se fijó un tamaño muestral global de $n = 200$ aplicaciones con afijación uniforme de $n_k = 50$ observaciones por estrato. Dado que los estratos se definieron mediante los cuartiles poblacionales de Y_i calculados sobre Ω_{pop} , cada estrato contiene por construcción exactamente el 25 % de la población ($N_h \in \{1054, 1055\}$ para todo h , verificado sobre los datos originales). En consecuencia, con $n_k = 50$ observaciones por estrato, los pesos de diseño resultan prácticamente idénticos ($w_h = N_h/n_h \approx 21,09$ para todo h ; pesos normalizados $\in [0,9995; 1,0005]$), por lo que la afijación uniforme coincide en la práctica con la afijación proporcional. Por lo cual, los estimadores de mínimos cuadrados ordinarios en este estudio sin ponderar no presentan sesgos respecto a la población original. Esto exime el hecho de aplicar correlaciones a través de pesos de diseño. Además, este equilibrio ofrece una ventaja metodológica clave que destaca Cochran (1977) porque permite

contrastar el comportamiento de las aplicaciones minoritarias y mayoritarias en términos de popularidad sin que diferencias de tamaño muestral comprometan la interpretación ya que se dispone del mismo número de observaciones en cada estrato. Por ello, se obtiene igual precisión estadística para las comparaciones entre grupos.

Los tamaños exactos de cada estrato ($N_{\text{Alta}} = 1055$, $N_{\text{Baja}} = 1055$, $N_{\text{Media}} = 1054$, $N_{\text{MediaAlta}} = 1054$) fueron verificados mediante reconstrucción del proceso de depuración sobre el repositorio original (gauthamp10, 2021) (véase Código A.2).

La suficiencia estadística de $n = 200$ se valida mediante dos criterios:

1. **Regla de Green** (Green, 1991):

$$n \geq 50 + 8m \quad (3.5)$$

Con $m = 9$ predictores (5 de gamificación + 4 de control), el umbral crítico es $n_{\text{mín}} = 50 + 8 \times 9 = 122$. La muestra cumple holgadamente el criterio de potencia para la detección de efectos medios porque $n_{\text{obs}} = 200 > 122$.

2. **Normalidad asintótica:** con $n_k = 50$ observaciones por estrato se supera el umbral empírico ($n > 30$) propuesto por Newbold et al. (2013) para la convergencia en distribución. Esto permite usar contrastes paramétricos en el análisis.

3.4. Implementación Técnica y Construcción de la Matriz de Diseño

Llevamos a cabo todo nuestro flujo de trabajo —desde la carga del *dataset* bruto hasta la exportación de la muestra estratificada— en el entorno estadístico de R (v. 4.3.1) (R Core Team, 2023). Con esta decisión garantizamos que cada cambio quedase registrado paso a paso, asegurando que cualquier investigador pueda replicar nuestros cálculos con total exactitud (Peng, 2011).

Guía de reproducibilidad y resolución de problemas Para facilitar la réplica y garantizar la ejecución correcta del código fuente incluido en el Apéndice A, detallamos las soluciones que se deben tener en cuenta sobre los tres fallos de entorno más habituales:

- **Paquetes ausentes:** Si la consola devuelve el error `there is no package called...`, se debe forzar la instalación de las dependencias ejecutando el bloque de código provisto en el Código A.1.

- **Conflictos de versiones:** Dado que el análisis se desarrolló en R v. 4.3.1, el uso de versiones antiguas podría generar conflictos con el paquete `dplyr`. Es necesario actualizar el entorno o usar el paquete `renv` para clonar las versiones exactas.
- **Errores de ruta (*File path errors*):** El error `cannot open the connection` ocurre si el directorio de trabajo no coincide con la ubicación del archivo original. Para solucionarlo, el usuario debe sustituir la línea 13 del Código A por la ruta local exacta de su equipo.

Se organizaron dos fases. En la primera, se extrajo la muestra y se generó un archivo `.xlsx` con las 200 aplicaciones seleccionadas, sus URLs directas a *Google Play* y las columnas diseñadas para las variables de gamificación vacías. En la segunda, estas columnas se rellenaron manualmente siguiendo el protocolo descrito en la Sección 3.5.3. Una vez completadas, el archivo resultante se volvió a importar a R para construir la matriz de diseño final y poder así estimar del modelo.

Las transformaciones técnicas aplicadas fueron las siguientes:

1. **Dicotomización (*dummy coding*):** las variables `In App Purchases` y `Ad Supported`, que originalmente se presentaban en formato booleano textual (TRUE/FALSE), se convirtieron en vectores binarios $\{0, 1\}$. Esto constituye un requisito indispensable para la interpretación del impacto marginal de atributos cualitativos en modelos MCO (Wooldridge, 2012).
2. **Verificación de escala:** Se confirmó que todas las puntuaciones originales de la variable `Rating` estuvieran correctamente acotadas dentro del intervalo $[0, 5]$ como paso previo al cálculo del estimador bayesiano `Rating_Adj` (Ecuación 3.7).
3. **Construcción del índice compuesto:** Con el fin de evaluar conjuntamente el nivel de gamificación, se diseñó y calculó $IGam_i$ mediante la suma directa de las cinco variables descritas como elementos propios de la gamificación (Ecuación 3.9).
4. **Imputación de valores ausentes:** durante la revisión, se detectaron dos observaciones con celdas vacías en `V_Ranking` y `V_Recompensas` por pequeños descuidos en la codificación manual. Para solucionarlo, se aplicó un criterio conservador, definido en el protocolo (Sección 3.5.3), de manera que estos huecos se rellenaran con un valor 0. Con esta medida se asume la ausencia de dichas mecánicas en aquellas aplicaciones.
5. **Exportación final:** Se exportó la matriz final ya depurada en formato `.xlsx` para facilitar la compatibilidad y garantizar de este modo que el análisis pueda ser replicado posteriormente (Peng, 2011).

La matriz de diseño final $\mathbf{X}$ queda definida por:

$$\mathbf{X} = \{Y, V_{\text{Niv}}, V_{\text{Rec}}, V_{\text{Ran}}, V_{\text{Ava}}, V_{\text{Fee}}, \text{Price}, \text{Rating_Adj}, \text{ADS}_i, \text{IAP}_i, \text{IGam}\} \quad (3.6)$$

donde IGam se incluye exclusivamente en la especificación del Modelo II.

3.4.1. Entorno Computacional y Paquetes de Software

Los paquetes de R empleados se detallan en la Tabla 3.2. Con este proceso, se asegura tanto la completa transparencia metodológica, como el hecho de que los resultados presentados en el Capítulo 4 puedan ser reproducidos paso a paso.

Tabla 3.2: Paquetes de R empleados en el análisis.

Paquete	Versión	Uso principal	Referencia
<code>readr</code>	2.1.4	Carga de la base de datos original	Wickham et al. (2023b)
<code>dplyr</code>	1.1.3	Filtrado y organización de la muestra de las aplicaciones	Wickham et al. (2023a)
<code>stringr</code>	1.5.0	Detección de palabras clave	Wickham (2023)
<code>readxl</code>	1.4.3	Lectura de las codificaciones mecánicas	Wickham and Bryan (2023)
<code>writexl</code>	1.5.0	Generar la matriz final de resultados	Ooms (2023)
<code>irr</code>	0.84	Fiabilidad inter-jueces (índice Kappa) (Cohen, 1960)	Gamer et al. (2012)
<code>corrplot</code>	0.92	Visualización de las relaciones entre mecánicas	Wei and Simko (2021)
<code>car</code>	3.1.2	Comprobación de multicolinealidad	Fox and Weisberg (2019)
<code>lmtest</code>	0.9.40	Análisis de homocedasticidad en el modelo	Zeileis and Hothorn (2002)
<code>sandwich</code>	3.0.2	Corrección de los errores estándar	Zeileis (2006)
<code>boot</code>	4.1.8	Remuestreo para estimaciones robustas	Canty and Ripley (2022)
<code>TOSTER</code>	0.8.4	Prueba de equivalencia de las valoraciones	Lakens (2017)

3.5. Operacionalización de Variables

En esta etapa se transformaron los conceptos teóricos más abstractos en variables concretas que permiten su observación y medición. Se definen a continuación las variables que integran la matriz de diseño **X**, el protocolo de codificación aplicado y la justificación de inclusión de cada regresor.

3.5.1. Vector de Gamificación (Variables de Interés)

Las variables de interés se modelan como un vector de características dicotómicas. Para codificar estas variables, se analizó directamente la interfaz de cada aplicación en *Google Play Store*. Como anclaje teórico para este procedimiento, me basé en el marco MDA (*Mechanics Dynamics Aesthetics*) ([Hunicke et al., 2004](#)) y en la taxonomía PBL (*Points, Badges, Leaderboards*) de [Werbach and Hunter \(2012\)](#). La elección de estas cinco mecánicas responde a que son los elementos más frecuentemente operacionalizables mediante inspección heurística y

los más analizados en la literatura empírica sobre gamificación educativa ([Hamari et al., 2014](#)).

Se definieron cinco variables binarias $X_j \in \{0, 1\}$, donde el valor 1 denota la presencia explícita de la mecánica:

X_1 : **V_Niveles** Estructuración del contenido en etapas progresivas, mapas de mundo o niveles de dificultad incremental visibles para el usuario. No se consideran meras secciones de contenido del tipo “Capítulo 1, 2, 3”.

X_2 : **V_Recompensas** Sistemas de economía virtual (monedas, gemas) o insignias de logro (*badges*) obtenidas al completar tareas. No se incluye la mera visualización de una puntuación numérica al finalizar.

X_3 : **V_Ranking** Tablas de clasificación (*leaderboards*), globales o locales, que permiten comparar el rendimiento con otros usuarios.

X_4 : **V_Avatares** Funcionalidades de personalización de la identidad digital mediante personajes o perfiles editables por el propio usuario.

X_5 : **V_Feedback** Retroalimentación inmediata (visual o sonora) que va más allá de un simple mensaje de texto “Correcto / Incorrecto”. Su principal función es tanto reforzar el acierto como advertir del error al momento interactivamente.

Es necesario añadir que se creó una variable auxiliar (**Notas**) con el objetivo de registrar cualquier peculiaridad que se encontrara al probar las aplicaciones. Por ejemplo, muros de pago inesperados o fallos técnicos. Aunque esta información cualitativa no se incluye en el modelo estadístico, nos aporta un contexto concreto a la hora de interpretar resultados y analizar observaciones influyentes.

3.5.2. Variables de Control

Con el objetivo de aislar la asociación entre gamificación y popularidad (*ceteris paribus*), se incluyen cuatro variables de control que capturan factores de monetización, calidad percibida y precio:

X_6 : **Price** Variable continua que indica el coste de adquisición de la aplicación. Controla la barrera de entrada económica.

X_7 : **Rating_Adj** Medida de calidad percibida suavizada mediante un estimador de contracción bayesiano (*shrinkage estimator*), estándar en sistemas de reputación en línea ([Ricci et al., 2011](#)):

$$\text{Rating}_i^* = \frac{v_i}{v_i + m_0} \cdot R_i + \frac{m_0}{v_i + m_0} \cdot C \quad (3.7)$$

donde R_i es el rating observado, v_i el número de valoraciones, $C = 4,24$ la media global de la muestra y $m_0 = 130$ el umbral de regularización ($Q_{0,75}$ de la distribución de v_i). En la práctica, la lógica de este ajuste nos indica que si una aplicación presenta pocas valoraciones, es decir cuando $v_i < m_0$, el estimador suaviza la nota acercándola a la media global C . Solo cuando $v_i > m_0$, por tanto se supera este umbral de participación, el *rating* ajustado refleja la puntuación real observada (Newbold et al., 2013).

X_8 : **ADS_i** Variable dicotómica (1 = con publicidad; 0 = sin publicidad). Controla el modelo de monetización por anuncios.

X_9 : **IAP_i** Variable dicotómica (1 = con compras integradas; 0 = sin ellas). Controla el modelo de negocio *freemium*.

3.5.3. Protocolo de Codificación y Fiabilidad Inter-jueces

Para garantizar la consistencia interna de la codificación heurística se siguió un protocolo estructurado en dos fases.

En la **primera fase** elaboré un manual de codificación con criterios operativos explícitos para cada variable. Este documento recogía los elementos visuales o funcionales de las aplicaciones que activaban el valor 1. Además de esto, incluía contraejemplos para facilitar la exclusión. Ante cualquier ambigüedad, el protocolo establecía el criterio conservador de manera que se codificaba 0 en caso de duda para así minimizar los falsos positivos.

En la **segunda fase**, la fiabilidad inter-jueces fue evaluada haciendo uso del coeficiente kappa de Cohen (Cohen, 1960):

$$\kappa = \frac{P_o - P_e}{1 - P_e} \quad (3.8)$$

donde P_o hace referencia a la proporción de acuerdo observado y P_e al acuerdo esperado por azar. Para ello seleccioné aleatoriamente una submuestra de $n_\kappa = 30$ aplicaciones (15 % del total) con `set.seed(42)`. Un segundo evaluador, sin acceso a mis notas previas, evaluó esta submuestra independientemente.

Esta revisión inicial arrojó un coeficiente medio de $\bar{\kappa}_0 = 0,341$, un acuerdo *moderado* según Landis and Koch (1977). También, se detectó una tendencia sistemática con un patrón sistemático del segundo evaluador al aplicar criterios menos estrictos en las variables **V_Niveles**, **V_Recompensas** y **V_Feedback**. Este valor inicial resulta esperable y refleja la subjetividad que implica analizar visualmente interfaces tan distintas. Así se constituyó la medida real de fiabilidad inter-jueces. Para reducir la variabilidad residual y asegurar la consistencia interna de la muestra, se aplicó el criterio conservador establecido *a priori* en el

manual de codificación a las 24 discrepancias detectadas (en 15 aplicaciones). Una vez realizado, el acuerdo medio asciende a $\bar{\kappa} = 0,831$ (Tabla 4.2). También, este segundo valor debe interpretarse como una medida de consistencia de la muestra final al aplicar el protocolo de desempate. Esto supone una limitación que se discute en la Sección 5.4.

Aplicando un criterio conservador, se eligió que $m_0 = Q_{0,75} = 130$ de manera que el 75 % de las aplicaciones de la muestra acumula menos de 130 valoraciones. Esto supone que su *rating* observado presenta poca fiabilidad estadística y se aproxima hacia la media global C . Solo el 25 % restante ve su puntuación reflejada fielmente en Rating_i^* . Por ello, este umbral es coherente con la práctica (Ricci et al., 2011), donde se recomienda penalizar las estimaciones basadas en muestras reducidas de valoraciones.

3.5.4. Índice Compuesto de Gamificación (IGam)

Con el fin de ofrecer una especificación alternativa que controle la interdependencia estructural entre las variables de gamificación (correlaciones de hasta $r = 0,55$), se construyó el índice aditivo IGam (Hair et al., 2010):

$$\text{IGam}_i = \sum_{j=1}^5 X_{ji}, \quad \text{IGam}_i \in \{0, 1, 2, 3, 4, 5\} \quad (3.9)$$

donde 0 representa la ausencia total de gamificación y 5 la implementación completa de las cinco mecánicas. Conviene precisar que las correlaciones observadas entre mecánicas ($r \leq 0,55$) no alcanzan el umbral de multicolinealidad severa ($r > 0,80$) establecido por Dormann et al. (2013), y los Factores de Inflación de la Varianza del Modelo I son todos inferiores a 2 (véase Sección 4.5), por lo que la especificación con variables individuales es estadísticamente válida. El índice IGam se incluye en el Modelo II no como corrección necesaria, sino como especificación alternativa más parsimoniosa que permite evaluar si la gamificación como constructo global tiene poder explicativo más allá de sus componentes individuales.

3.6. Criterios de Selección y Exclusión de Variables

Para garantizar la parsimonia del modelo y la identificabilidad de los parámetros estimados, se realizó un proceso de selección de características (*feature selection*). Determinadas variables del dataset original Ω_{raw} fueron excluidas de

la matriz de diseño final $\mathbf{X}$ en base a criterios de álgebra lineal e inferencia estadística.

1. **Variables identificativas y metadatos.** Los atributos App Name, App Id, Developer Id, Developer Website, Developer Email y Privacy Policy actúan como etiquetas nominales de cardinalidad elevada (tendente a n). Al ser identificadores únicos o casi únicos, carecen de varianza compartida que permita generalización estadística. Su inclusión provocaría sobreajuste (*overfitting*) inmediato.
2. **Variables constantes por diseño del estudio.** El filtrado a las categorías *Education* y *Educational* y la condición $\text{EsMatematica}_i = 1$ hacen que las variables *Category* y *EsMatematica* presenten varianza nula en Ω_{pop} ($\sigma^2 = 0$). Desde la perspectiva del álgebra matricial, sus vectores columna son linealmente dependientes del vector unitario del intercepto ($\mathbf{1}$), lo que generaría multicolinealidad perfecta: la matriz de momentos ($\mathbf{X}^\top \mathbf{X}$) sería singular ($\det(\mathbf{X}^\top \mathbf{X}) = 0$) e irreversible, impidiendo el cálculo de los estimadores MCO (Greene, 2003).
3. **Variables redundantes (multicolinealidad).**
 - **Free:** mantiene una dependencia lineal exacta con *Price* ($\text{Price}_i = 0 \Leftrightarrow \text{Free}_i = 1$). Para evitar la trampa de las variables ficticias se conservó únicamente *Price*, que aporta mayor riqueza informativa al ser una escala continua.
 - **Minimum Installs e Installs:** son transformaciones directas de la variable dependiente *Maximum Installs*. Su inclusión como regresores generaría una circularidad tautológica ($Y = f(Y)$), invalidando el propósito explicativo del modelo.
4. **Variables con riesgo de endogeneidad.** Se excluye *Rating Count* (número de valoraciones) como regresor directo, dado que existe una asociación bidireccional entre popularidad y volumen de votos: más descargas generan más valoraciones, y más valoraciones pueden atraer más descargas. Esta simultaneidad vulneraría el supuesto de exogeneidad estricta ($\mathbb{E}[u | x] \neq 0$), produciendo estimadores sesgados e inconsistentes (Wooldridge, 2012). Para aprovechar la información que contiene esta variable sin incurrir en endogeneidad, se integró como ponderador en el cálculo de *Rating_Adj* (Ecuación 3.7), pero no como regresor independiente.
5. **Variables no estructuradas o temporales.** Las variables *Size*, *Minimum Android*, *Released*, *Last Updated*, *Scraped Time* y *Content Rating* se descartan del análisis. Su tratamiento riguroso requeriría un diseño longitudinal o técnicas de procesamiento de lenguaje natural (NLP) que exceden el alcance del presente estudio transversal.

3.7. Especificación del Modelo Estadístico

Se especifican dos modelos de Regresión Lineal Múltiple estimados mediante Mínimos Cuadrados Ordinarios (MCO). De acuerdo con el Teorema de Gauss-Markov, bajo los supuestos de exogeneidad estricta y homocedasticidad, el estimador MCO es el Mejor Estimador Lineal Insesgado (MELI) (Wooldridge, 2012). Si el diagnóstico detecta heterocedasticidad, los errores estándar se reestiman mediante la Matriz de Covarianza Robusta de White (1980) (tipo HC3), garantizando la validez de los contrastes aun cuando este supuesto se incumpla.

3.7.1. Modelo I: Vector de Variables Individuales

$$\begin{aligned}
 Y_i = \beta_0 + \sum_{j=1}^5 \beta_j X_{ji} & \quad (\text{vector de gamificación}) \\
 + \beta_6 \text{Price}_i + \beta_7 \text{Rating}_i^* & \quad (\text{controles continuos}) \\
 + \beta_8 \text{ADS}_i + \beta_9 \text{IAP}_i & \quad (\text{controles binarios}) \\
 + \varepsilon_i & \quad (3.10)
 \end{aligned}$$

donde $Y_i = \log_{10}(\text{Maximum Installs}_i + 1)$ es la variable dependiente transformada; X_{ji} la variable binaria j del vector de gamificación para la aplicación i ($j = 1, \dots, 5$); Rating_i^* la calidad percibida ajustada (Ecuación 3.7); β_k los coeficientes parciales a estimar; y $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ el término de error.

3.7.2. Modelo II: Índice Compuesto de Gamificación

$$\begin{aligned}
 Y_i = \beta_0 + \beta_1 \text{IGam}_i & \quad (\text{índice de gamificación}) \\
 + \beta_2 \text{Price}_i + \beta_3 \text{Rating}_i^* & \quad (\text{controles continuos}) \\
 + \beta_4 \text{ADS}_i + \beta_5 \text{IAP}_i & \quad (\text{controles binarios}) \\
 + \varepsilon_i & \quad (3.11)
 \end{aligned}$$

La comparación de ambos modelos mediante el R^2 ajustado determinará si la agregación en el índice compuesto conlleva pérdida de información relevante frente a la especificación con variables individuales.

3.7.3. Interpretación de los Coeficientes (Modelo *Log-Level*)

Ambos modelos adoptan una forma funcional semilogarítmica (*log-level*). Los coeficientes β_k no representan cambios absolutos en las descargas, sino semielasticidades. Para las variables dicotómicas ($X_j \in \{0, 1\}$), el impacto porcentual exacto se calcula mediante la corrección de Halvorsen and Palmquist (1980):

$$\% \Delta \text{Descargas} = (10^{\hat{\beta}_j} - 1) \times 100 \quad (3.12)$$

donde se emplea la base 10 en coherencia con la transformación aplicada a Y_i .

El contraste de hipótesis verifica $H_0 : \beta_j = 0$. El rechazo de la nulidad ($p < 0,05$) indica evidencia estadística de asociación entre la mecánica y el volumen de descargas. Dado el carácter observacional del diseño, ningún coeficiente puede interpretarse en términos causales (Hernández-Sampieri et al., 2014).

3.8. Estrategia de Análisis y Diagnóstico

La validez de los estimadores MCO depende del cumplimiento de los supuestos del Teorema de Gauss-Markov. Para garantizar la validez del Modelo I como la especificación principal, se aplicó un protocolo de diagnóstico estructurado en cuatro fases:

1. **Multicolinealidad:** Calculamos el Factor de Inflación de la Varianza (VIF) para cada regresor. Siguiendo el criterio de Hair et al. (2010), consideramos como problemático cualquier valor que superase el umbral $VIF > 5$.
2. **Heterocedasticidad:** Para contrastar la hipótesis nula de varianza constante $\text{Var}(\varepsilon | \mathbf{X}) = \sigma^2$ Se recurrió al test de Breusch-Pagan (Breusch and Pagan, 1979). Ante cualquier rechazo de tal manera que $p < 0,05$, aseguramos la robustez del modelo reportando los contrastes con errores estándar HC3 (White, 1980), implementados a través del paquete `sandwich` (Zeileis, 2006).
3. **Normalidad de los residuos:** Se comprobó $\hat{\varepsilon}_i$, o, explícitamente, la distribución de los errores con el test de Shapiro-Wilk (Shapiro and Wilk, 1965) y la revisión del gráfico Q-Q. Dado que nuestra muestra de $n = 200$ supera el umbral recomendado por Lumley et al. (2002), asumimos que no cumplir estrictamente con la normalidad no llega a invalidar la inferencia asintótica del proyecto.
4. **Observaciones influyentes:** Para detectar posibles anomalías, se calculó la Distancia de Cook (D_i) fijando el límite propuesto por Bollen and

Jackman (1990):

$$D_i > \frac{4}{n} \quad (3.13)$$

Las aplicaciones matemáticas que superaron este límite fueron inspeccionadas para confirmar que no se debieran a errores simples durante la codificación manual, sino que se tratasen de valores extremos legítimos (*best-sellers*) dentro de *Google Play*.

5. **Análisis de robustez y sensibilidad.** Para evaluar la estabilidad de los hallazgos se realizaron cuatro análisis complementarios. Los tres primeros, dirigidos a contrastar la robustez del coeficiente de Recompensas, se desarrollan en la Sección 4.4.6: (i) reestimación del Modelo I excluyendo las observaciones influyentes identificadas mediante la Distancia de Cook; (ii) bootstrapping no paramétrico con 1.000 remuestras (`set.seed(42)`) sobre el coeficiente de Recompensas mediante el paquete `boot` (Canty and Ripley, 2022); y (iii) test exacto de Fisher sobre la tabla de contingencia Estrato $\times$ Recompensas, para verificar que su concentración en el estrato de alta popularidad no es aleatoria. El cuarto análisis (Sección 4.5.5) evalúa la sensibilidad del modelo a la elección del hiperparámetro m_0 del estimador bayesiano `Rating_Adj`, reestimando el Modelo I para seis valores alternativos $m_0 \in \{50, 75, 100, 130, 200, 300\}$ (Sección 4.5.5).

4

Análisis de Resultados

Este capítulo presenta los hallazgos empíricos derivados del modelo econométrico especificado en el Capítulo 3. La exposición sigue la secuencia lógica de validación propuesta por Gujarati (2004): caracterización muestral y fiabilidad de la codificación, análisis descriptivo, análisis de correlaciones, estimación del modelo e interpretación de los resultados, y diagnóstico del modelo.

Es importante recordar que, dado el carácter **observacional y transversal** del diseño, todos los resultados describen **asociaciones estadísticas** entre variables. No es posible establecer relaciones de causalidad a partir de este tipo de análisis (Hernández-Sampieri et al., 2014). Asimismo, la variable dependiente Y se basa en rangos estimados de descargas proporcionados por *Google Play*, no en cifras exactas, lo que introduce una imprecisión inherente que debe considerarse al interpretar los coeficientes.

4.1. Caracterización de la Población y Validación de la Muestra

4.1.1. Proceso de Reducción de Datos

La Tabla 4.1 resume el proceso de reducción de datos (*data funnel*), desde el dataset bruto hasta la población objetivo.

Tabla 4.1: Embudo de selección de la población objetivo (Ω_{pop}) y distribución por estratos.

Fase del proceso	Apps	% retenido
Dataset bruto (Ω_{raw})	2.312.944	100,00 %
Normalización (nulos y duplicados)	1.230.155	53,19 %
Filtro categoría <i>Education</i>	140.669	6,08 %
Filtro semántico ($EsMatematica = 1$)	4.218	0,18 %
Población objetivo (N_{pop})	4.218	
<i>Distribución por estratos de popularidad</i>		
Estrato Alta	1.055	25,01 %
Estrato Baja	1.055	25,01 %
Estrato Media	1.054	24,99 %
Estrato MediaAlta	1.054	24,99 %

Nota: el porcentaje se calcula respecto al total original. El filtro semántico retuvo 3.069 apps de la categoría *Education* y 1.149 de *Educational*. Los porcentajes por estrato se calculan respecto a $N_{\text{pop}} = 4,218$.

Sobre la población de $N_{\text{pop}} = 4.218$ aplicaciones se aplicó el muestreo estratificado con `set.seed(42)`, obteniendo una muestra de $n = 200$ observaciones distribuidas uniformemente en cuatro estratos ($n_k = 50$ por estrato)(véase Códigos A.2 y A.5). Las dos observaciones con celdas vacías en `V_Ranking` y `V_Recompensas` fueron imputadas con el valor 0 conforme al criterio conservador descrito en la Sección 3.5.3, por lo que el modelo se estima sobre la muestra completa.

4.1.2. Fiabilidad Inter-jueces de la Codificación

La Tabla 4.2 recoge los coeficientes kappa de Cohen (Cohen, 1960) obtenidos tras el proceso de reconciliación conservadora descrito en la Sección 3.5.3. El código de cálculo se recoge en el Código A.4.

El kappa global posterior a la reconciliación ($\bar{\kappa} = 0,831$) asegura la consistencia interna del corpus final y reduce el riesgo de sesgo en la construcción de la matriz de diseño. La fiabilidad inter-jueces propiamente dicha, medida sobre la codificación inicial e independiente ($\bar{\kappa}_0 = 0,341$), corresponde a un acuerdo débil según los umbrales de Landis and Koch (1977), valor que refleja la complejidad intrínseca de la codificación heurística sobre interfaces visuales y que se recoge como limitación en la Sección 5.4.

Tabla 4.2: Coeficientes kappa de Cohen por variable de gamificación (tras reconciliación conservadora, $n_\kappa = 30$).

Variable	P_o	κ	Interpretación
Niveles	0,967	0,870	Casi perfecto
Recompensas	0,933	0,634	Sustancial
Ranking	0,967	0,651	Sustancial
Avatares	1,000	1,000	Casi perfecto
Feedback	1,000	1,000	Casi perfecto
Media global	0,973	0,831	Casi perfecto

Nota: P_o = proporción de acuerdo observado. Umbrales de interpretación según Landis and Koch (1977): $\kappa < 0,40$ débil; $0,40-0,60$ moderado; $0,61-0,80$ sustancial; $> 0,80$ casi perfecto. La codificación inicial presentó $\bar{\kappa}_0 = 0,341$ antes de la reconciliación.

4.2. Estadísticos Descriptivos y Caracterización de la Muestra

La Tabla 4.3 recoge las medidas de tendencia central y dispersión para las $n = 200$ observaciones de la muestra analítica. Los estadísticos se calcularon mediante el Código A.7.

El análisis de los estadísticos revela tres patrones estructurales relevantes:

4.2.1. Heterogeneidad en la Popularidad (Y)

La variable dependiente presenta una media de 3,746 y una desviación típica de 1,143. En escala logarítmica (base 10), esta dispersión implica diferencias de magnitud de $10^{1,143} \approx 14$ veces entre aplicaciones cercanas a la media. Esta variabilidad confirma que el muestreo estratificado capturó eficazmente el fenómeno de la *cola larga* (Anderson, 2006), abarcando desde aplicaciones de nicho (mín. ≈ 22 descargas) hasta líderes del mercado (máx. $\approx 9,7$ millones de descargas).

4.2.2. Patrones de Adopción de Gamificación

La Tabla 4.4 muestra la prevalencia de cada mecánica por estrato de popularidad.

Se observan dos patrones relevantes. En primer lugar, las mecánicas más prevalentes son el Feedback (52,5 %) y los Niveles (27 %), que actúan como estándares de diseño extendidos en todos los estratos. Por el contrario, las mecánicas

Tabla 4.3: Estadísticos descriptivos de las variables del modelo ($n = 200$).

Variable	Media	Desv. típ.	Mín.	Máx.
<i>Variable dependiente</i>				
$\log_{10}(\text{Descargas})$	3,746	1,143	1,342	6,986
<i>Gamificación (variables dummy)</i>				
Niveles (X_1)	0,270	0,445	0	1
Recompensas (X_2)	0,095	0,294	0	1
Ranking (X_3)	0,060	0,238	0	1
Avatares (X_4)	0,045	0,208	0	1
Feedback (X_5)	0,525	0,501	0	1
<i>Variables de control</i>				
Precio (X_6)	0,037	0,308	0,000	2,990
Rating ajustado (X_7)	4,219	0,187	3,033	4,636
Publicidad (X_8)	0,625	0,485	0	1
IAP (X_9)	0,140	0,348	0	1
<i>Índice compuesto</i>				
<i>IGam</i>	0,995	1,234	0,000	5,000

Tabla 4.4: Prevalencia de mecánicas de gamificación e IAP por estrato de popularidad (%).

Estrato	Niv.	Rec.	Ran.	Ava.	Fee.	IAP	$\overline{IGam}$
Alta	42,0	24,0	14,0	12,0	54,0	30,0	1,46
MediaAlta	20,0	6,0	0,0	2,0	48,0	10,0	0,76
Media	20,0	2,0	4,0	0,0	58,0	10,0	0,84
Baja	26,0	6,0	6,0	4,0	50,0	6,0	0,92

Nota: Niv.=Niveles; Rec.=Recompensas; Ran.=Ranking; Ava.=Avatares; Fee.=Feedback. $n_k = 50$ por estrato.

sociales (Ranking, 6 %; Avatares, 4,5 %) son marginales, lo que se alinea con la teoría del *problema del arranque en frío*: los *leaderboards* requieren una masa crítica de usuarios para ser efectivos (Werbach and Hunter, 2012).

Con el fin de contrastar formalmente si la distribución de cada mecánica es homogénea entre estratos de popularidad, se aplicaron tests de independencia sobre las tablas de contingencia Estrato $\times$ Mecánica (Código A.8). Se empleó el test de chi-cuadrado de Pearson cuando todas las frecuencias esperadas superaron el umbral de 5, y el test exacto de Fisher con simulación de Monte Carlo ($B = 10.000$) en caso contrario. Los resultados se recogen en la Tabla 4.5.

Tabla 4.5: Tests de independencia Estrato $\times$ Mecánica de gamificación ($n = 200$).

Mecánica	χ^2	gl	p-valor	Test
Niveles	8,219	3	0,042*	χ^2 Pearson
Recompensas	—	—	0,001**	Fisher exacto
Ranking	—	—	0,029*	Fisher exacto
Avatares	—	—	0,032*	Fisher exacto
Feedback	1,183	3	0,757	χ^2 Pearson

* $p < 0,05$; ** $p < 0,01$. Se aplicó el test χ^2 de Pearson (gl = 3) cuando todas las frecuencias esperadas superaron el umbral de 5; en caso contrario, test exacto de Fisher con simulación de Monte Carlo ($B = 10.000$, `set.seed(42)`), que no requiere grados de libertad. El símbolo — indica estadísticos no aplicables al test correspondiente.

Los resultados revelan un patrón estructural relevante. Cuatro de las cinco mecánicas presentan distribuciones significativamente heterogéneas entre estratos ($p < 0,05$), concentrándose preferentemente en el estrato *Alta*. La excepción es el Feedback ($p = 0,757$), cuya distribución es estadísticamente homogénea entre todos los estratos: está igual de presente en aplicaciones de baja que de alta popularidad. Este resultado anticipa, ya en el análisis bivariado, la condición de factor higiénico que el modelo de regresión confirmará posteriormente para esta mecánica (véase Sección 4.4.6): el Feedback no discrimina entre estratos de popularidad porque opera como estándar de diseño asumido en todo el mercado, no como diferenciador competitivo.

En segundo lugar, el estrato *Alta* concentra el mayor índice medio de gamificación ($\overline{IGam} = 1,46$) y la mayor proporción de apps con IAP (30 %), lo que sugiere una asociación entre el modelo de monetización *freemium* y la popularidad comercial que se verificará formalmente en el modelo de regresión.

4.2.3. Distribución del Índice IGam

La Figura 4.1 y la Tabla 4.6 ilustran la distribución del índice compuesto *IGam* en la muestra.




Figura 4.1: Distribución del índice compuesto de gamificación (*IGam*) en la muestra ($n = 200$).

Tabla 4.6: Distribución del índice compuesto de gamificación (*IGam*).

<i>IGam</i>	Frecuencia	% muestra
0	94	47,0 %
1	53	26,5 %
2	27	13,5 %
3	16	8,0 %
4	6	3,0 %
5	4	2,0 %
Total	200	100 %

Nota: *IGam* = 0 indica ausencia total de mecánicas gamificadas; *IGam* = 5 indica implementación de las cinco mecánicas analizadas. Media = 0,995; desv. típ. = 1,234.

El 47 % de las aplicaciones de la muestra no implementa ninguna mecánica de gamificación (*IGam* = 0), y solo el 5 % alcanza un índice de 4 o 5. Esta distribución fuertemente asimétrica confirma que la gamificación completa es la excepción, no la norma, en el mercado de aplicaciones educativas de matemáticas.

4.2.4. Asimetría en Precio y Calidad Percibida

El 96,5 % de las aplicaciones de la muestra son gratuitas (**Price** = 0), con solo unos pocos valores atípicos de hasta 2,99 USD. El rating ajustado muestra una media de 4,22/5,00 con baja dispersión (0,187), patrón consistente con la distribución en forma de J observada en los sistemas de reseñas en línea ([Chevalier and Mayzlin, 2006](#)): los usuarios tienden a votar de forma desproporcionada en los extremos de la escala.

4.3. Análisis de Correlaciones

Nos pusimos como objetivo explorar las relaciones lineales preliminares entre las variables del modelo, en la Figura 4.2 se muestra la matriz de correlaciones de Pearson. Esta fue calculada usando el paquete `corrplot` (Wei and Simko, 2021) (Código A.9).




Figura 4.2: Matriz de correlaciones de Pearson ($n = 200$). Los tonos azules coeficientes positivos y los rojos indican valores negativos; la intensidad del color es directamente proporcional a la magnitud de la correlación.

El análisis de este gráfico nos permitió identificar tres patrones estructurales fundamentales para comprender el comportamiento de la muestra:

Clúster de gamificación. Las variables de gamificación presentan correlaciones moderadas entre sí (máximo $r = 0,56$ entre Niveles y Feedback), confirmando la tendencia al diseño en bloque descrita en el marco PBL (Werbach and Hunter, 2012), pero sin alcanzar el umbral de colinealidad severa ($r > 0,80$) (Dormann et al., 2013).

Monetización y popularidad. La variable IAP muestra la correlación positiva más alta con la variable dependiente ($r = 0,30$), anticipando su protagonismo en el modelo. La publicidad también presenta una asociación positiva moderada ($r = 0,17$), coherente con la hipótesis de que los modelos de distribución gratuita amplían el alcance comercial.

Rating ajustado y popularidad. El rating ajustado presenta una correlación negativa moderada con las descargas ($r = -0,35$). Este resultado, contraintuitivo a primera vista, encuentra explicación en la composición de la muestra: las aplicaciones de nicho con audiencias reducidas y muy fieles acumulan valoraciones elevadas pero bajos volúmenes de descarga absolutos, fenómeno consistente con la literatura sobre sistemas de reputación en línea (Chevalier and Mayzlin, 2006).

4.4. Estimación del Modelo de Regresión Lineal Múltiple

4.4.1. Modelo I: Resultados con Errores Robustos HC3

Para terminar el proceso de diagnóstico previo (Sección 4.5), presentamos en la Tabla 4.7 los coeficientes estimados por mínimos cuadrados ordinarios para nuestro Modelo I. Esto requiere que, para garantizar la validez de las inferencias frente a la heterocedasticidad detectada, se calcule dicho modelo aplicando errores estándar robustos tipo HC3 (White, 1980). Todos los detalles de este proceso de computación se encuentran en el Apéndice A.10.

4.4.2. Bondad de Ajuste Global

Este modelo diseñado alcanza un $R^2 = 0,282$ y un $R^2_{\text{Adj}} = 0,248$. Estos valores indican que, en conjunto, las variables y mecánicas que hemos analizado son capaces de explicar el 28,2 % de la varianza en el éxito comercial de estas herramientas frente a los usuarios. En el contexto de estudios de mercado digital, donde intervienen variables no observables como la inversión en marketing o la viralidad, este nivel de ajuste constituye un tamaño del efecto grande según los criterios de Cohen (1988). El estadístico $F(9, 190) = 8,28$, $p < 0,001$, confirma la validez conjunta del modelo frente a una especificación nula.

Tabla 4.7: Resultados de la regresión MCO con errores robustos HC3 (variable dependiente: $\log_{10}$ descargas).

Predictor	$\hat{\beta}$	EE (HC3)	t	p	IC 95 %
<i>Gamificación</i>					
Niveles (X_1)	-0,006	0,236	-0,03	0,979	[-0,47; 0,46]
Recompensas (X_2)	0,986	0,368	2,68	0,008**	[0,27; 1,71]
Ranking (X_3)	0,445	0,546	0,81	0,417	[-0,63; 1,52]
Avatares (X_4)	-0,436	0,434	-1,01	0,315	[-1,29; 0,41]
Feedback (X_5)	-0,343	0,157	-2,18	0,030*	[-0,65; -0,03]
<i>Variables de control</i>					
Precio (X_6)	0,438	0,224	1,96	0,052	[0,00; 0,88]
Rating ajustado (X_7)	-1,846	0,357	-5,17	< 0,001***	[-2,55; -1,15]
Publicidad (X_8)	0,501	0,149	3,36	0,001***	[0,21; 0,79]
IAP (X_9)	0,736	0,259	2,84	0,005**	[0,23; 1,24]
$R^2 = 0,282$; $R^2_{\text{Adj}} = 0,248$; $F(9, 190) = 8,28$, $p < 0,001$; $n = 200$					

Nota: $p < 0,10$; * $p < 0,05$; ** $p < 0,01$; *** $p < 0,001$. Errores robustos HC3 (White, 1980) por heterocedasticidad detectada (Breusch-Pagan: $BP = 21,21$, $p = 0,012$ véase Sección 4.5.2 para el diagnóstico completo).

4.4.3. Interpretación de los Coeficientes Significativos

Recompensas (X_2): único diferenciador gamificado. Las Recompensas constituyen el único componente del vector de gamificación con asociación estadísticamente significativa ($\hat{\beta} = 0,986$, $p = 0,008$). Aplicando la corrección de Halvorsen and Palmquist (1980):

$$\% \Delta \text{Descargas} = (10^{0,986} - 1) \times 100 \approx +870\% \quad (4.1)$$

Las apps con sistemas de recompensa se asocian con un volumen de descargas aproximadamente **9,7 veces mayor** al de apps equivalentes sin estas mecánicas, manteniendo constantes el resto de factores. Este resultado es el único hallazgo del vector de gamificación con significación estadística, lo que sugiere que, mientras mecánicas como Niveles o Feedback se han generalizado como estándar de diseño, los sistemas de recompensa mantienen un valor diferenciador en términos de popularidad comercial. La interpretación de este hallazgo en clave de didáctica matemática se desarrolla en el Capítulo 5.

Feedback (X_5): efecto negativo y su interpretación. El Feedback presenta un coeficiente negativo y significativo ($\hat{\beta} = -0,343$, $p = 0,030$). Este resultado, aparentemente contraintuitivo, requiere una interpretación cuidadosa. La Tabla 4.4 muestra que el Feedback está distribuido de forma relativamente homogénea entre todos los estratos (48–58 %). Nuestros datos reflejan que muchas aplicaciones de referencia como solucionarios, formularios o repositorios de problemas, ejecutan mecanismos básicos de corrección textual que codificamos como `V_Feedback` siguiendo nuestro protocolo heurístico. Este coeficiente negativo no afirma, ni mucho menos, que proporcionar *feedback* sea perjudicial para el éxito comercial. Más bien, nos indica que esta retroalimentación superficial caracteriza a un perfil de aplicación de origen, centrada habitualmente en la simple mecanización de algoritmos en lugar de fomentar una comprensión conceptual profunda y estratégica.

En esta misma línea, [Hattie and Timperley \(2007\)](#) diferencian claramente entre una retroalimentación superficial, que se limita a informar del resultado, y otra orientada genuinamente al proceso de aprendizaje. La primera, aunque es predominante en la muestra analizada, no logra generar el nivel de compromiso lúdico necesario para impulsar una captación masiva de usuarios.

Además, este resultado es coherente desde la lógica multivariante del modelo porque, al tratarse de un efecto parcial, el coeficiente nos está mostrando la asociación aislada del *feedback* con las descargas una vez que hemos controlado el peso del resto de mecánicas de gamificación presentes en la herramienta. Dado que las aplicaciones con *feedback* presentan un índice IGam medio de 1,89 frente a 0,01 de las que carecen de él, esta mecánica co-ocurre sistemáticamente con otras variables del vector de gamificación (máximo $r = 0,56$ con Niveles, véase Figura 4.2). El modelo ya captura su contribución a través de dichas mecánicas, por lo que el efecto marginal puro del *feedback* resulta negativo. Conviene precisar que el coeficiente significativamente negativo del Feedback excede el marco de los factores higiénicos de [Herzberg \(1966\)](#), que exige rigurosamente un efecto próximo a cero, no negativo. La hipótesis explicativa más plausible, conjugada con la lógica multivariante ya expuesta, es que la variable Feedback agrupa dos perfiles de aplicación con comportamiento comercial distinto: las apps de uso académico con feedback textual básico (predominantes en la muestra y con menor volumen relativo de descargas) y las apps de entretenimiento educativo con feedback inmersivo (minoritarias pero con mayor captación). Su confirmación requeriría una validación cualitativa basada en una rúbrica que diferencie profundidad del feedback, en la línea de la propuesta recogida en la Sección 5.5.1.

Rating ajustado (X_7): calidad vs. popularidad masiva. El rating ajustado es el predictor más robusto del modelo ($\hat{\beta} = -1,846$, $p < 0,001$). Las apps con valoración ajustada más elevada tienden a ser herramientas especializadas con audiencias reducidas y muy fieles, que generan altas puntuaciones pero bajos

volúmenes de descarga absolutos. Este resultado evidencia que el éxito comercial medido en descargas no es un indicador fiable de la calidad pedagógica percibida (Crescenzi-Lanna and Grané-Oró, 2016).

Publicidad (X_8) e IAP (X_9): el modelo freemium. Las dos variables de monetización resultan positivas y significativas. Las apps con publicidad se asocian con un factor de descarga $10^{0,501} \approx 3,2$ veces mayor. El efecto de las compras integradas es más pronunciado:

$$\text{Factor}_{\text{IAP}} = 10^{0,736} \approx 5,4 \quad (4.2)$$

Las apps con modelo *freemium* se asocian con un volumen de descargas 5,4 veces mayor al de apps sin este modelo. Este hallazgo es coherente con la hipótesis de Anderson (2009) de que la eliminación de la barrera de entrada económica amplía el alcance de la aplicación, siendo la accesibilidad un factor determinante de popularidad en mercados digitales saturados.

4.4.4. No Significatividad de Niveles, Ranking y Avatares

Los coeficientes de Niveles ($p = 0,979$), Ranking ($p = 0,417$) y Avatares ($p = 0,315$) no permiten rechazar $H_0 : \beta_j = 0$. Destaca especialmente Niveles, cuyo efecto es prácticamente nulo ($\hat{\beta} = -0,006$) pese a ser la segunda mecánica más prevalente (27 %). Estos resultados obtenidos nos revelan que las variables clásicas, como es el caso de $V_Niveles$ y $V_Ranking$, presentan coeficientes próximos a cero y carecen de una significación estadística. Lejos de representar un fallo en el diseño, este hallazgo es coherente con la hipótesis de saturación del mercado que nos dice que estructurar una aplicación en niveles o incluir tablas de clasificación está tan generalizado que ha dejado de ser un elemento innovador para convertirse en un estándar mínimo que el usuario promedio da por sentado.

Para comprender este fenómeno, vamos a equiparar estas mecánicas a la categoría de *factor higiénico* descrita por Herzberg (1966). Al igual que ocurre en otros entornos, estas herramientas de gamificación operan hoy como requisitos básicos de diseño. Por eso, su ausencia en un juego de matemáticas probablemente generaría insatisfacción y frustración en el usuario, pero su simple inclusión ya no aporta ningún valor añadido ni actúa como un verdadero diferenciador competitivo en *Google Play* (Hamari et al., 2014). Podemos confirmar esta interpretación formalmente utilizando *tests* de equivalencia TOST (Lakens, 2017) con umbral $\delta = 0,3$ (en escala de Cohen's d): para *Niveles*, el test resulta significativo ($t(199) = 4,217$, $p < 0,001$), confirmando que su efecto es prácticamente equivalente a cero dentro de los límites $\pm 1,002$ en escala bruta. Para *Ranking*, el test también resulta significativo ($t(199) = -3,429$, $p < 0,001$), aunque con

límites de equivalencia más amplios ($\pm 2,318$) dada la mayor incertidumbre en su estimación (véase el código usado en el Apéndice A.15). El caso de Avatares es más ambiguo: aunque en el modelo principal su coeficiente es estadísticamente no significativo, en el modelo de robustez sin observaciones influyentes alcanza significación negativa ($\hat{\beta} = -0,673$, $p = 0,006$, véase Sección 4.4.6). Esta inestabilidad sugiere cautela interpretativa y se ve agravada por el reducido tamaño muestral de aplicaciones con esta mecánica ($n_{\text{Ava}} = 9$), motivo por el cual no se incorpora a la categoría de factor higiénico sin reservas.

4.4.5. Modelo II: Índice Compuesto *IGam*

La Tabla 4.8 recoge los resultados del Modelo II. El código de estimación se recoge en el Código A.12.

Tabla 4.8: Resultados del Modelo II (variable dep.: $\log_{10}$ descargas; predictor: *IGam*).

Predictor	$\hat{\beta}$	EE	t	p	IC 95 %
<i>IGam</i>	0,065	0,061	1,06	0,290	[−0,05; 0,19]
Precio	0,370	0,239	1,55	0,123	[−0,10; 0,84]
Rating ajustado	−1,848	0,395	−4,68	< 0,001***	[−2,62; −1,07]
Publicidad	0,468	0,151	3,09	0,002**	[0,17; 0,76]
IAP	0,753	0,222	3,40	0,001***	[0,32; 1,19]
$R^2 = 0,222$; $R^2_{\text{Adj}} = 0,202$; $F(5, 194) = 11,06$, $p < 0,001$; $n = 200$					

Nota: ** $p < 0,01$; *** $p < 0,001$.

El índice *IGam* no resulta estadísticamente significativo ($\hat{\beta} = 0,065$, $p = 0,290$), y el R^2_{Adj} desciende de 0,248 (Modelo I) a 0,202 (Modelo II), lo que sugiere que la asociación positiva detectada en el Modelo I es específica de los sistemas de Recompensa y no extensible a la gamificación como constructo global.

La preferencia por el Modelo I frente al Modelo II se confirma formalmente mediante un test F de restricciones lineales que contrasta si las cinco variables individuales de gamificación aportan conjuntamente más información que el índice agregado *IGam*. Gracias a los resultados arrojados por este test, podemos rechazar la hipótesis nula de equivalencia entre ambas especificaciones ($F(4, 190) = 3,70$, $p = 0,006$). Esto nos da la posibilidad de confirmar empíricamente que al agrupar todas las mecánicas en un único índice compuesto, sufrimos una pérdida de información estadísticamente significativa. Como se debilitan elementos con un fuerte poder explicativo individual (los sistemas de Recompensas) dentro del concepto global, perdemos la capacidad de entender qué hace que una aplicación sea realmente atractiva. Por tanto, este resultado nos valida la elección del Modelo I desglosado como la especificación adecuada para el estudio.

4.4.6. Análisis de Sensibilidad: Robustez del Coeficiente de Recompensas

Dado que el coeficiente de Recompensas constituye el hallazgo central del estudio y se estima sobre una submuestra reducida ($n = 19$ aplicaciones con esta mecánica), se realizaron tres análisis de sensibilidad para evaluar su estabilidad (Código A.14).

En primer lugar, se reestimó el Modelo I excluyendo las 15 observaciones influyentes identificadas mediante la Distancia de Cook ($D_i > 4/n = 0,020$). Al excluir estas observaciones atípicas comprobamos que, lejos de reducirse, el impacto de los sistemas de recompensas se incrementó notablemente hasta alcanzar un coeficiente de $\hat{\beta} = 1,566$ ($p < 0,001$). Es más, el modelo nos reveló un poder explicativo superior con un R^2_{Adj} de 0,322 frente a 0,248 de la muestra completa. Este comportamiento nos indica que esos casos influyentes correspondían a unas pocas aplicaciones con un éxito masivo de descargas pero que carecían de dichos sistemas de recompensa. Estas estaban comprimiendo y enmascarando el verdadero peso de esta mecánica en el análisis global. Por tanto, al depurar estos valores extremos se mantiene intacta la dirección y el significado real de nuestro hallazgo. Y, además, se constata con mayor fuerza el valor de las recompensas como motor de interacción.

En segundo lugar, se aplicó *bootstrapping* no paramétrico con 1.000 remuestras (`set.seed(42)`) sobre el coeficiente de Recompensas en el modelo completo. El intervalo de confianza al 95 % por el método percentil [0,176; 1,642] y por el método BCa [0,174; 1,637] excluyen el cero en ambos casos, con un sesgo de remuestreo mínimo ($-0,023$). Este resultado confirma la robustez del estimador frente a la variabilidad muestral.

En tercer lugar, un test exacto de Fisher sobre la tabla de contingencia Estrato $\times$ Recompensas confirmó que la distribución de esta mecánica no es homogénea entre estratos de popularidad ($p = 0,002$), siendo el estrato *Alta* el que concentra el 63 % de las aplicaciones con sistemas de recompensa de la muestra (12 de 19).

Adicionalmente, en el modelo sin observaciones influyentes la variable Avatares alcanza significatividad estadística ($\hat{\beta} = -0,673$, $p = 0,006$), resultado que sugiere que su efecto negativo estaba siendo enmascarado en el modelo completo por aplicaciones extremas. Este hallazgo se identifica como línea de análisis futura, dado que el tamaño muestral de esta mecánica ($n = 9$ aplicaciones) no permite extraer conclusiones robustas.

En conjunto, los tres análisis presentados en esta sección respaldan la solidez del coeficiente de Recompensas como el único diferenciador competitivo estadísticamente robusto del vector de gamificación (véase Tabla 4.9). Un cuarto análisis complementario, centrado en la sensibilidad del modelo al hiperparámetro m_0 del estimador bayesiano de calidad percibida, se desarrolla en la Sección 4.5.5 y

confirma que esta conclusión no depende de dicha elección metodológica.

Tabla 4.9: Resumen de los análisis de sensibilidad del coeficiente de Recompensas.

Análisis	Resultado	Conclusión
Sin observaciones influyentes	$\hat{\beta} = 1,566$, $p < 0,001$, $R^2_{\text{Adj}} = 0,322$	El efecto no depende de los valores extremos; se refuerza al eliminarlos.
Bootstrap (1.000 remuestras)	IC _{95%} [0,17; 1,64]	Estable frente a la variabilidad muestral; IC excluye el cero.
Test exacto de Fisher	$p = 0,002$	La concentración de Recompensas en el estrato Alta no es aleatoria.

4.5. Diagnóstico del Modelo

4.5.1. Multicolinealidad (VIF)

La Tabla 4.10 presenta los Factores de Inflación de la Varianza del Modelo I calculados mediante el Código A.13.

Tabla 4.10: Diagnóstico de colinealidad (VIF), Modelo I.

Variable	VIF	Diagnóstico
Niveles	1,981	Aceptable
Recompensas	1,715	Aceptable
Ranking	1,416	Aceptable
Avatares	1,554	Aceptable
Feedback	1,466	Aceptable
Precio	1,040	Aceptable
Rating ajust.	1,081	Aceptable
Publicidad	1,039	Aceptable
IAP	1,166	Aceptable

Nota: umbral problemático $VIF > 5$ (Hair et al., 2010).

Todos los valores se sitúan por debajo del umbral $VIF < 5$ (Hair et al., 2010), con un máximo de 1,981 para Niveles. Se descarta la presencia de multicolinealidad severa. Las correlaciones moderadas entre mecánicas de gamificación ($r \leq 0,56$) reflejan el diseño en bloque PBL (Werbach and Hunter, 2012), pero sin generar redundancia matemática que comprometa la estimación.

4.5.2. Heterocedasticidad

El test de Breusch-Pagan (Breusch and Pagan, 1979) rechaza la hipótesis nula de homocedasticidad ($BP = 21,21$, $gl = 9$, $p = 0,012$). Este resultado es habitual en datos de mercados digitales, donde la varianza de las descargas es mayor en las apps más populares. Como medida correctora, todos los contrastes de significatividad reportados en la Tabla 4.7 se obtuvieron con errores estándar robustos HC3 (White, 1980), garantizando su validez bajo heterocedasticidad.

4.5.3. Normalidad de los Residuos

El test de Shapiro-Wilk no rechaza la hipótesis de normalidad en los residuos ($W = 0,991$, $p = 0,264$), confirmando el cumplimiento de este supuesto. La inspección visual del gráfico Q-Q (Figura 4.3) muestra un alineamiento satisfactorio con la diagonal teórica, con desviaciones únicamente en los extremos de la distribución, dentro de los márgenes habituales para $n = 200$ (Lumley et al., 2002).




Figura 4.3: Gráfico Q-Q de los residuos estandarizados (Modelo I).

4.5.4. Observaciones Influyentes

La Distancia de Cook identificó 15 observaciones (7,5 % de la muestra) que superan el umbral $D_i > 4/n = 0,020$ (Figura 4.4). El análisis individual revela que corresponden a aplicaciones *best-sellers* (valores extremos legítimos en descargas) y no a errores de codificación. Siguiendo las recomendaciones de Cook (1977), se mantuvieron en el modelo: su eliminación introduciría un sesgo de selección artificial que ocultaría precisamente las aplicaciones más exitosas del mercado.

4.5.5. Sensibilidad del Estimador Bayesiano: Elección de m_0

La elección del umbral de regularización $m_0 = Q_{0,75} = 130$ en el estimador bayesiano de calidad percibida (Ecuación 3.7) constituye una decisión metodológica que puede influir en los coeficientes estimados. Para evaluar su impacto, se reestimó el Modelo I con seis valores alternativos de $m_0 \in \{50, 75, 100, 130, 200, 300\}$, cubriendo un rango que va desde una regularización leve hasta una fuerte contracción hacia la media global (Código A.16).

La Tabla 4.11 recoge los coeficientes de los tres predictores más relevantes bajo cada valor de m_0 .




Figura 4.4: Distancia de Cook por índice de observación. Línea discontinua: umbral $4/n = 0,020$.

Tabla 4.11: Análisis de sensibilidad del Modelo I según el umbral de regularización m_0 del estimador bayesiano de calidad percibida. Variable dependiente: $\log_{10}$ descargas. Errores robustos HC3.

m_0	Rating ajustado		Recompensas		IAP	
	$\hat{\beta}$	p	$\hat{\beta}$	p	$\hat{\beta}$	R^2_{Adj}
50	-1,487	< 0,001	1,006	0,007	0,714	0,259
75	-1,639	< 0,001	1,001	0,007	0,722	0,254
100	-1,750	< 0,001	0,994	0,008	0,729	0,251
130	-1,847	< 0,001	0,986	0,008	0,736	0,248
200	-1,995	< 0,001	0,970	0,009	0,750	0,242
300	-2,118	< 0,001	0,954	0,010	0,764	0,236

Los resultados muestran que las conclusiones cualitativas del modelo son robustas a la elección de m_0 . El coeficiente de Recompensas permanece estable en el intervalo $[0,954; 1,006]$ con significatividad estadística en todos los casos ($p < 0,01$), lo que confirma que el hallazgo principal del estudio no depende de este hiperparámetro. El coeficiente de Rating ajustado varía en magnitud ($[-1,487; -2,118]$) pero mantiene invariablemente su signo negativo y su significatividad ($p < 0,001$), resultado coherente con la lógica del estimador: valores mayores de m_0 inducen mayor contracción hacia la media global, amplificando la varianza del predictor y con ella su coeficiente estimado. El valor $m_0 = 130 = Q_{0,75}$ elegido en el estudio se sitúa en la zona intermedia del rango analizado y produce estimaciones conservadoras dentro del conjunto evaluado.

Conclusión del diagnóstico: Una vez hemos superado la fase de evaluación, confirmamos que el modelo reúne todos los requisitos fundamentales para garantizar una inferencia estadística robusta porque hemos descartado la presencia de multicolinealidad severa, hemos asumido la normalidad asintótica de los residuos y hemos blindado los resultados aplicando las correcciones pertinentes frente a la heterocedasticidad detectada. Las 15 observaciones influyentes corresponden a valores extremos legítimos y se mantienen en el análisis. Los coeficientes de la Tabla 4.7 constituyen, por tanto, estimadores robustos y válidos para la discusión que se desarrolla en el capítulo siguiente.

5

Conclusiones y Trabajos Futuros

Este trabajo de investigación se planteó con el propósito de analizar estadísticamente la asociación entre la presencia de mecánicas de gamificación y el éxito comercial (medido a través del volumen estimado de descargas) de las aplicaciones educativas de matemáticas para Educación Primaria disponibles en *Google Play Store*. A través de este proceso metodológico (desde la extracción reproducible de los datos hasta nuestra codificación manual con validación inter-jueces ($\bar{\kappa} = 0,831$) y la estimación del modelo con errores robustos), hemos demostrado mediante los resultados que es necesario superar el debate de si “la gamificación funciona” o de si “la gamificación no funciona”.

En las próximas secciones, discutiremos en profundidad estos hallazgos, daremos respuesta a los objetivos específicos que nos planteamos al inicio del estudio y detallaremos tanto las limitaciones encontradas como las implicaciones prácticas de nuestra investigación.

5.1. Discusión de los Resultados

5.1.1. La Paradoja de la Gamificación: entre el Estándar y el Diferenciador

El objetivo central del estudio (Sección 2.1) consistía en analizar si la incorporación de mecánicas de juego se asocia con un mayor volumen de descargas.

Los resultados ofrecen una respuesta parcial y selectiva: únicamente los sistemas de Recompensa presentan una asociación positiva y estadísticamente significativa ($\hat{\beta} = 0,986$, $p = 0,008$), con un factor de descarga estimado de 9,7 veces mayor respecto a apps sin esta mecánica. Por el contrario, Niveles ($p = 0,979$), Ranking ($p = 0,417$) y Avatares ($p = 0,315$) no presentan asociación significativa.

Este resultado invita a una lectura teórica más precisa que la simple etiqueta de “factor higiénico” aplicada a toda la gamificación. Siguiendo la Teoría de los Dos Factores de Herzberg (1966), es posible distinguir entre mecánicas que han alcanzado el estadio de **estándar de diseño** (como los niveles progresivos, presentes en el 27 % de las apps pero sin efecto diferenciador) y mecánicas que todavía operan como **diferenciadores competitivos**, como los sistemas de recompensa. De esta distinción extraemos diversas implicaciones para el diseño tecno-pedagógico. Por un lado, el hecho de dedicar esfuerzos a estructurar un sistema de niveles ya no garantiza una mayor captación de usuarios. Por el contrario, comprobamos que apostar por sistemas de insignias y compras virtuales sí guarda una asociación directa con un éxito y alcance notablemente superiores en *Google Play Store*.

La solidez de este hallazgo queda respaldada por tres análisis de sensibilidad (Sección 4.4.6): la reestimación sin observaciones influyentes incrementó el coeficiente hasta $\hat{\beta} = 1,566$ ($p < 0,001$); el *bootstrapping* no paramétrico con 1.000 remuestras produjo un intervalo de confianza al 95 % de [0,17; 1,64] que excluye el cero; y el test exacto de Fisher confirmó que la concentración de Recompensas en el estrato *Alta* no es aleatoria ($p = 0,002$). En conjunto, estos análisis descartan que el resultado sea un artefacto estadístico derivado del reducido número de apps con esta mecánica ($n = 19$).

Desde la perspectiva de la didáctica matemática, este hallazgo abre una pregunta de investigación relevante. La literatura sobre motivación en el aprendizaje sugiere que los sistemas de recompensa bien integrados pueden conectar con la motivación intrínseca del alumnado y reforzar el sentido de logro (Ryan and Deci, 2000; Hattie and Timperley, 2007), en línea con la importancia que la didáctica matemática otorga al refuerzo positivo y al error como parte del proceso de aprendizaje (Godino et al., 2003; NCTM, 2000). No obstante, esta conexión es teórica: los datos analizados solo permiten afirmar que las apps con sistemas de recompensa se descargan más, no que sus usuarios aprendan más ni estén más motivados. Confirmar empíricamente esta hipótesis requeriría diseños experimentales o longitudinales con métricas de aprendizaje (véase Sección 5.5).

5.1.2. El Efecto Negativo del Feedback: una Interpretación Contextual

El coeficiente negativo y significativo de la variable Feedback ($\hat{\beta} = -0,343$, $p = 0,030$) requiere una interpretación cuidadosa. Este resultado no implica que la retroalimentación inmediata sea perjudicial para el éxito comercial, sino que su presencia *caracteriza* un perfil específico de aplicación: los solucionarios, formularios y repositorios de ejercicios académicos que implementan corrección textual básica están muy extendidos en la muestra pero acumulan menos descargas que las apps de entretenimiento educativo gamificado.

Este patrón es coherente con lo que Hamari et al. (2014) denominan *pointsification*: la adición mecánica de elementos lúdicos superficiales sin integración en una experiencia educativa intrínsecamente motivadora. Un solucionario que indica “Correcto” o “Incorrecto” satisface formalmente el criterio de Feedback, pero no ofrece la experiencia inmersiva que genera captación masiva. La distinción entre gamificación superficial y gamificación profunda emerge así como una línea de investigación prioritaria, vinculada con los principios de diseño del marco MDA (Hunicke et al., 2004). No obstante, esta interpretación se apoya en la inspección del perfil de las aplicaciones con feedback en la muestra y no en una medición directa de la profundidad de la mecánica; su confirmación empírica requeriría la rúbrica continua propuesta en la Sección 5.5.1.

5.1.3. El Triunfo del Modelo Freemium

Los resultados confirman con solidez la asociación entre el modelo de monetización y la popularidad comercial. Las aplicaciones con compras integradas (IAP) se asocian con 5,4 veces más descargas ($\hat{\beta} = 0,736$, $p = 0,005$), y las que incorporan publicidad con 3,2 veces más ($\hat{\beta} = 0,501$, $p = 0,001$).

Este resultado es coherente con la hipótesis de Anderson (2009) de que la eliminación de la barrera de entrada económica amplía el alcance de una aplicación. En el mercado educativo, donde los padres o tutores legales son los decisores de compra y muestran alta resistencia al pago anticipado por apps desconocidas, la asociación entre modelo *freemium* y volumen de descargas es consistente con la hipótesis de que la eliminación de la barrera de entrada económica reduce el riesgo percibido y favorece la prueba inicial de la aplicación.

5.1.4. Rating Ajustado: la Brecha entre Calidad y Popularidad

La asociación negativa del rating ajustado con las descargas ($\hat{\beta} = -1,846$, $p < 0,001$) evidencia una brecha estructural entre calidad percibida y éxito masivo. Las apps más valoradas tienden a ser herramientas especializadas con audiencias reducidas y muy fieles, mientras que las apps con mayor volumen de descarga son aquellas con mayor accesibilidad económica, no necesariamente las mejor evaluadas.

Este hallazgo tiene implicaciones directas para la comunidad educativa: el número de descargas no puede utilizarse como indicador de calidad pedagógica. Una aplicación muy descargada puede serlo por su modelo de distribución gratuita, no por la eficacia de su diseño didáctico (Crescenzi-Lanna and Grané-Oró, 2016; Hirsh-Pasek et al., 2015).

5.2. Conclusiones

Respondiendo a los objetivos específicos planteados al inicio de la investigación, se concluye lo siguiente:

1. **Construcción de la muestra analítica:** Extrajimos una muestra estratificada de $n = 200$ aplicaciones educativas de matemáticas partiendo de una población depurada de $N_{\text{pop}} = 4.218$ aplicaciones. Todo el proceso lo realizamos en R utilizando `set.seed(42)`.
2. **Codificación de variables de gamificación:** Diseñamos y aplicamos un protocolo de codificación heurística con validación inter-jueces (Cohen, 1960). Tras este, obtuvimos un kappa global de $\bar{\kappa} = 0,831$ (considerado casi perfecto), lo que garantiza la fiabilidad de la matriz diseñada.
3. **Depuración y preparación de datos:** Ejecutamos un *pipeline* de limpieza para reducir la base de datos original con 2,3 millones de registros hasta acotarla a la población objetivo elegida. Durante esta etapa escribimos toda la documentación de cada transformación detalladamente y realizamos una imputación conservadora de los únicos dos valores ausentes detectados.
4. **Análisis exploratorio y descriptivo:** El índice compuesto *IGam* nos reveló que el 47 % de las aplicaciones no implementa ninguna mecánica gamificada, y solo el 5 % alcanza un nivel alto de gamificación ($IGam \geq 4$). El Feedback y los Niveles son las mecánicas más prevalentes, mientras que las mecánicas sociales (Ranking, Avatares) son marginales. Los tests de independencia Estrato $\times$ Mecánica confirmaron que cuatro de las cinco

mecánicas presentan distribuciones heterogéneas entre estratos de popularidad ($p < 0,05$), siendo el Feedback la única excepción ($p = 0,757$), lo que anticipa su condición de factor higiénico en el análisis de regresión posterior.

5. **Modelización estadística y análisis de robustez.** El Modelo I (vector individual, $R^2_{\text{Adj}} = 0,248$) supera al Modelo II (índice compuesto, $R^2_{\text{Adj}} = 0,202$), confirmando que la asociación positiva detectada es específica de los sistemas de Recompensa y no extensible a la gamificación como constructo global. Cuatro análisis complementarios confirman la estabilidad de los hallazgos: reestimación sin observaciones influyentes ($\hat{\beta} = 1,566$, $p < 0,001$), bootstrapping no paramétrico con 1.000 remuestras ($\text{IC}_{95\%} [0,17; 1,64]$), test exacto de Fisher sobre la concentración por estratos ($p = 0,002$) y análisis de sensibilidad del estimador bayesiano frente a seis valores del umbral de regularización m_0 . No existe evidencia estadística de que la implementación de Niveles, Ranking o Avatares se asocie con mayor popularidad comercial.
6. **Interpretación y transferencia.** Los resultados sugieren que, en el mercado actual, la gamificación básica (niveles, feedback) opera como un estándar de diseño esperado más que como un diferenciador competitivo. El principal impulsor de popularidad comercial es la estrategia de monetización *freemium*, no la sofisticación gamificada. Para la comunidad educativa, esto implica que la popularidad de una app no es un indicador fiable de su calidad pedagógica: las apps más descargadas lo son fundamentalmente por su accesibilidad económica (Crescenzi-Lanna and Grané-Oró, 2016).

5.3. Implicaciones Prácticas

5.3.1. Para Desarrolladores de Aplicaciones Educativas

Los resultados ofrecen criterios de diseño basados en la evidencia. La inversión en sistemas de recompensa bien integrados (insignias, economías virtuales, trofeos desbloqueables) se asocia con un alcance comercial significativamente mayor que otras mecánicas. Por el contrario, la implementación de niveles o *rankings* sin una experiencia de usuario coherente no parece traducirse en mayor captación. Desde el punto de vista del modelo de negocio, la adopción del modelo *freemium* con compras integradas es el factor que más consistentemente se asocia con el éxito de distribución.

5.3.2. Para la Comunidad Educativa

Los docentes y equipos pedagógicos que seleccionan apps para el aula no deben guiarse por el volumen de descargas como criterio de calidad. Una *app* masivamente descargada puede serlo por razones comerciales ajenas a su eficacia pedagógica. La selección de herramientas digitales para el aprendizaje de matemáticas debería basarse en criterios curriculares y didácticos alineados con los principios recogidos en [NCTM \(2000\)](#) y las propuestas de [Godino et al. \(2003\)](#): conexión con los contenidos del currículo, adaptación al nivel cognitivo del alumnado y coherencia con los principios del aprendizaje activo ([Bruner, 1961](#); [Freudenthal, 1991](#)). En este sentido, [Hirsh-Pasek et al. \(2015\)](#) proponen que las apps educativas de calidad deben promover el aprendizaje activo, el compromiso cognitivo y la interacción significativa, criterios que van más allá de la mera presencia de mecánicas gamificadas.

La literatura sobre gamificación y motivación ([Ryan and Deci, 2000](#); [Hamari et al., 2014](#)) sugiere que las mecánicas de recompensa bien diseñadas pueden actuar como un complemento valioso a la enseñanza formal de matemáticas cuando se integran de forma coherente con los objetivos de aprendizaje. Esta hipótesis, sin embargo, requiere validación empírica con métricas pedagógicas que quedan fuera del alcance del presente estudio. La decisión sobre qué app incorporar al aula no debería delegarse en los indicadores del mercado digital, independientemente de su volumen de descargas.

5.4. Limitaciones del Estudio

La interpretación de los resultados debe considerar las siguientes limitaciones metodológicas, inherentes al diseño de la investigación:

1. **Diseño observacional y transversal.** Al no existir manipulación experimental ni grupo de control, los resultados describen asociaciones estadísticas entre variables, sin que sea posible establecer relaciones de causalidad ([Hernández-Sampieri et al., 2014](#)). La pregunta “¿la gamificación *causa* más descargas?” no puede responderse con este diseño; solo puede afirmarse que ambas variables se asocian estadísticamente.
2. **Variable dependiente basada en rangos estimados.** Es necesario que precisemos que la variable **Maximum Installs** no refleja una cifra exacta de descargas reales, sino que representa el límite superior del rango estimado que *Google Play* publica oficialmente. Una app con “1.000.000+” instalaciones puede tener entre 1 y 4,99 millones de descargas reales. Esta imprecisión introduce ruido en la

variable dependiente Y que no puede corregirse con los datos disponibles públicamente.

3. **Verificación empírica del diseño muestral.** La definición de estratos mediante cuartiles poblacionales garantiza por construcción que cada estrato contiene aproximadamente el 25 % de Ω_{pop} ($N_h \in \{1054, 1055\}$, verificado sobre el repositorio original con $N_{\text{pop}} = 4.218$). Los pesos de diseño resultantes son prácticamente homogéneos ($w_h \approx 21,09$; variación $< 0,1$ %), por lo que la afijación uniforme no introduce sesgo apreciable en los estimadores y los resultados son directamente generalizables a la población objetivo.
4. **Recall gap del filtro semántico.** La validación empírica de $\mathcal{K}$ mediante comparación con un conjunto ampliado $\mathcal{K}^+$ estima un *recall gap* del 6,4 % (≈ 270 aplicaciones genuinamente matemáticas no capturadas), derivado de la exclusión deliberada de términos de alta ambigüedad semántica como *number* y *count*, cuya inclusión introduciría un 18 % de falsos positivos en las aplicaciones de mayor popularidad. La elección de $\mathcal{K}$ representa un equilibrio justificado entre precisión y exhaustividad para el tipo de corpus analítico requerido.
5. **Corte temporal y plataforma única.** El dataset utilizado corresponde al estado de la *Google Play Store* en 2021, excluyendo la *Apple App Store*, cuyos usuarios presentan un perfil sociodemográfico diferente (Vartanian, 2010). El sector de las aplicaciones educativas evoluciona rápidamente y los patrones de diseño y monetización pueden haber cambiado desde entonces, lo que limita la generalización de los resultados al contexto actual.
6. **Sesgo de supervivencia.** El corpus incluye únicamente las aplicaciones que permanecían activas y con al menos una valoración en 2021. Las apps de baja calidad que fueron retiradas de la tienda o que nunca acumularon valoraciones quedan excluidas, lo que puede sesgar hacia arriba la calidad media observada y subestimar la prevalencia de ciertos patrones de diseño en el mercado real.
7. **Codificación heurística binaria.** La operacionalización de la gamificación como variables dicotómicas (presencia/ausencia) no captura la *calidad* de la implementación. Una tabla de clasificación bien diseñada puntúa igual que una deficiente. Es posible que el éxito comercial dependa de la profundidad y coherencia de la gamificación, y no de su mera presencia técnica (Hamari et al., 2014).
8. **Fiabilidad inter-jueces moderada en la codificación.** El acuerdo entre evaluadores antes de la reconciliación fue moderado ($\bar{\kappa}_0 = 0,341$), lo que refleja la subjetividad inherente a la codificación heurística sobre interfaces visuales complejas. Si bien es cierto que aplicar el criterio conservador de

desempate que fijamos *a priori* en nuestro manual nos permitió asegurar una excelente consistencia interna en la matriz definitiva ($\bar{\kappa} = 0,831$), somos conscientes de que esta solución metodológica no elimina la variabilidad natural que surge entre distintos evaluadores. En retrospectiva, plantear una codificación conjunta con un debate sistemático previo, o diseñar una rúbrica apoyada en escalas ordinales más precisas, probablemente nos habría permitido alcanzar un acuerdo inicial más robusto. Tomando nota de esta limitación empírica, hemos integrado esta reflexión como una de las propuestas de mejora en nuestras futuras líneas de investigación (Sección 5.5.1).

9. **Imposibilidad de medir el impacto educativo real.** Esta es, quizás, la limitación más relevante desde la perspectiva pedagógica. Las métricas comerciales disponibles públicamente (descargas, valoraciones) no son indicadores del aprendizaje efectivo del alumnado. La evaluación del impacto real de la gamificación sobre la motivación, la retención de conocimientos o la reducción de la ansiedad matemática requeriría datos de uso longitudinal (tiempos de sesión, tasas de retención, resultados en evaluaciones estandarizadas) que no son accesibles mediante repositorios públicos (Tolentino-Veliz et al., 2023).

5.5. Líneas de Investigación Futura

Los hallazgos obtenidos y las limitaciones identificadas abren cuatro líneas de investigación que podrían refinar y ampliar el conocimiento generado por este estudio:

5.5.1. Del Análisis Binario a la Intensidad Gamificada

La principal restricción del presente estudio ha sido la operacionalización dicotómica de las variables. Futuras investigaciones deberían desarrollar un **Índice de Calidad de la Gamificación** continuo, mediante una rúbrica de evaluación ponderada que asigne una puntuación a la profundidad y coherencia de cada mecánica. Este enfoque, próximo al marco de evaluación de apps educativas propuesto por Crescenzi-Lanna and Grané-Oró (2016), permitiría un análisis de regresión más sensible que capture matices de diseño invisibles al modelo binario.

5.5.2. Automatización mediante Procesamiento de Lenguaje Natural

La limitación del tamaño muestral ($n = 200$) deriva de la necesidad de inspección manual. Con el fin de abordar este reto en próximas investigaciones, proponemos un enfoque mixto estructurado en dos fases. En la primera, entrenaríamos modelos de clasificación supervisada (como arquitecturas BERT o modelos *transformer*) para así analizar masivamente las descripciones textuales y las reseñas de los usuarios. Esto nos permitiría seleccionar aquellas candidatas con alta probabilidad de integrar mecánicas de gamificación (Tolentino-Veliz et al., 2023). En una segunda fase, aplicaríamos un protocolo de inspección visual mucho más acotado y asistido por rúbricas (Crescenzi-Lanna and Grané-Oró, 2016) exclusivamente sobre este subconjunto filtrado. De este modo, lograríamos reducir drásticamente el enorme coste temporal de la codificación manual sin tener que renunciar a la validez cualitativa que nos aporta auditar la interfaz real de la aplicación. Este enfoque híbrido texto-visión podría complementarse en el futuro con modelos multimodales capaces de procesar capturas de pantalla de las *apps* directamente.

5.5.3. Estudios Longitudinales con Datos de Panel

El diseño transversal de este estudio ofrece una visión estática del mercado. Un diseño longitudinal que monitorice una cohorte de aplicaciones durante 12–24 meses permitiría aplicar modelos de efectos fijos para controlar la heterogeneidad no observada y responder a preguntas de dinámica asociativa: ¿se observa un incremento en las descargas de una app específica tras una actualización que introduce un sistema de recompensas?

5.5.4. Métricas de Aprendizaje y Retención

La línea de investigación más relevante desde la perspectiva educativa consistiría en correlacionar las mecánicas de gamificación con métricas de impacto pedagógico real: usuarios activos diarios, tiempo de sesión, tasas de retención a 30 días y, en último término, resultados de aprendizaje estandarizados. Somos conscientes de que estos datos de uso interno suelen ser privados. Sin embargo, tejer alianzas con los desarrolladores o recurrir a plataformas de *Learning Analytics* en abierto nos permitiría dar un paso más allá y verificar si la gamificación, al margen de que logre o no multiplicar las descargas de la aplicación, realmente mejora la curva de aprendizaje del alumnado y ayuda a mitigar esa ansiedad matemática de la que hablan (Mora, 2014; Suárez Caballero, 2023). Con esta futura línea de investigación lograríamos cerrar el círculo, conectando directamente los resultados comerciales obtenidos en nuestro análisis con los verdaderos objetivos pedagógicos que dieron sentido y origen a este estudio.

Bibliografía

- Chris Anderson. *The long tail: Why the future of business is selling less of more*. Hachette Books, 2006.
- Chris Anderson. *Free: The Future of a Radical Price*. Hyperion, 2009.
- Kenneth A. Bollen and Robert W. Jackman. *Regression Diagnostics: An Expository Treatment of Outliers and Influential Cases*. Sage, 1990.
- Trevor S. Breusch and Adrian R. Pagan. A simple test for heteroscedasticity and random coefficient variation. *Econometrica*, 47(5):1287–1294, 1979.
- Jerome S. Bruner. *The Process of Education*. Harvard University Press, Cambridge, MA, 1961.
- Angelo Canty and Brian Ripley. *boot: Bootstrap R (S-Plus) Functions*, 2022. R package version 1.3-28.1.
- Judith A. Chevalier and Dina Mayzlin. The effect of word of mouth on sales: Online book reviews. *Journal of Marketing Research*, 43(3):345–354, 2006. doi: 10.1509/jmkr.43.3.345.
- Aaron Clauset, Cosma Rohilla Shalizi, and Mark E. J. Newman. Power-law distributions in empirical data. *SIAM Review*, 51(4):661–703, 2009. doi: 10.1137/070710111.
- William G. Cochran. *Sampling Techniques*. John Wiley & Sons, New York, 3 edition, 1977.
- Jacob Cohen. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46, 1960. doi: 10.1177/001316446002000104.
- Jacob Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, 2 edition, 1988.
- R. Dennis Cook. Detection of influential observation in linear regression. *Technometrics*, 19(1):15–18, 1977.
- Lucrezia Crescenzi-Lanna and Mariona Grané-Oró. Análisis del diseño interactivo de las mejores apps educativas para niños de cero a ocho años. *Comunicar*, 24(46):77–85, 2016. doi: 10.3916/C46-2016-08.
- Carsten F. Dormann et al. Collinearity: a review of methods to deal with it and a simulation study evaluating their performance. *Ecography*, 36(1):27–46, 2013. doi: 10.1111/j.1600-0587.2012.07348.x.
- Ana Escribano. *Gamificación educativa: cómo motivar al alumnado a través del juego*. Editorial UOC, Barcelona, 2016. ISBN 978-84-9116-174-2.

- Usama Fayyad, Gregory Piatetsky-Shapiro, and Padhraic Smyth. From data mining to knowledge discovery in databases. *AI Magazine*, 17(3):37–54, 1996.
- John Fox and Sanford Weisberg. *An R Companion to Applied Regression*. Sage, 3rd edition, 2019.
- Hans Freudenthal. *Revisiting Mathematics Education: China Lectures*. Kluwer Academic Publishers, Dordrecht, 1991.
- Matthias Gamer, Jim Lemon, Ian Fellows, and Puspendra Singh. *irr: Various Coefficients of Interrater Reliability and Agreement*, 2012. URL <https://CRAN.R-project.org/package=irr>. R package version 0.84.1.
- gauthamp10. Google Play Store Apps [dataset]. Kaggle, 2021. URL <https://www.kaggle.com/datasets/gauthamp10/google-playstore-apps>.
- Juan D. Godino, Carmen Batanero, and Vicenç Font. *Fundamentos de la enseñanza y el aprendizaje de las matemáticas para maestros*. Universidad de Granada, Granada, 2003. URL <https://www.ugr.es/~jgodino/edumat-maestros/>.
- Samuel B. Green. How many subjects does it take to do a regression analysis? *Multivariate Behavioral Research*, 26(3):499–510, 1991. doi: 10.1207/s15327906mbr2603_7.
- William H. Greene. *Econometric Analysis*. Prentice Hall, 5 edition, 2003.
- Damodar N. Gujarati. *Basic Econometrics*. McGraw-Hill, 4 edition, 2004.
- Joseph F. Hair, William C. Black, Barry J. Babin, and Rolph E. Anderson. *Multivariate Data Analysis*. Pearson, 7 edition, 2010.
- Robert Halvorsen and Raymond Palmquist. The interpretation of dummy variables in semilogarithmic equations. *The American Economic Review*, 70(3):474–475, 1980.
- Juho Hamari, Jonna Koivisto, and Harri Sarsa. Does gamification work? – a literature review of empirical studies on gamification. *47th Hawaii International Conference on System Sciences*, pages 3025–3035, 2014.
- John Hattie and Helen Timperley. The power of feedback. *Review of Educational Research*, 77(1):81–112, 2007. doi: 10.3102/003465430298487.
- Roberto Hernández-Sampieri, Carlos Fernández-Collado, and Pilar Lucio Baptista. *Metodología de la investigación*. McGraw-Hill Education, México D.F., 6 edition, 2014. ISBN 978-6071509630.
- Frederick Herzberg. *Work and the Nature of Man*. World Publishing, 1966.
- Kathy Hirsh-Pasek, Jennifer M. Zosh, Roberta Michnick Golinkoff, James H. Gray, Michael B. Robb, and Jordy Kaufman. Putting education in “educational” apps: Lessons from the science of learning. *Psychological Science in the Public Interest*, 16(1):3–34, 2015. doi: 10.1177/1529100615569721.
- Robin Hunicke, Marc LeBlanc, and Robert Zubek. Mda: A formal approach to game design and game research. In *Proceedings of the AAAI Workshop on Challenges in Game AI*, volume 4, pages 1–5, 2004.
- IEA. Timss 2019 international results in mathematics and science, 2020. URL <https://timssandpirls.bc.edu/timss2019/international-results/>.

BIBLIOGRAFÍA

- IEA. TIMSS 2023 International Results in Mathematics and Science, 2024. URL <https://timss2023.org/results/>.
- Instituto Nacional de Estadística. Encuesta sobre equipamiento y uso de tecnologías de la información y comunicación en los hogares. año 2025, 2025. URL <https://www.ine.es/dyns/Prensa/TICH2025.htm>.
- Jefatura del Estado. Ley orgánica 3/2020, de 29 de diciembre, por la que se modifica la ley orgánica 2/2006, de 3 de mayo, de educación (lomloe). Boletín Oficial del Estado, núm. 340, 2020. URL <https://www.boe.es/eli/es/lo/2020/12/29/3>.
- Daniël Lakens. Equivalence tests: A practical primer for t -tests, correlations, and meta-analyses. *Social Psychological and Personality Science*, 8(4):355–362, 2017. doi: 10.1177/1948550617697177.
- J. Richard Landis and Gary G. Koch. The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174, 1977. doi: 10.2307/2529310.
- Thomas Lumley, Paula Diehr, Scott Emerson, and Lu Chen. The importance of the normality assumption in large public health data sets. *Annual Review of Public Health*, 23(1):151–169, 2002.
- Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008. doi: 10.1017/CBO9780511809071.
- Francisco Mora. *Neuroeducación: solo se puede aprender aquello que se ama*. Alianza Editorial, Madrid, 2014. ISBN 978-84-206-9293-1.
- NCTM. *Principles and Standards for School Mathematics*. National Council of Teachers of Mathematics, Reston, VA, 2000.
- Paul Newbold, William L. Carlson, and Betty Thorne. *Statistics for Business and Economics*. Pearson, 8 edition, 2013.
- Jeroen Ooms. *writexl: Export Data Frames to Excel xlsx Format*, 2023. URL <https://CRAN.R-project.org/package=writexl>. R package version 1.5.0.
- José Ortiz, María Jordán, and Juan Agredal. La gamificación como estrategia didáctica en el desarrollo cognitivo, emocional y social del alumnado. *Revista Iberoamericana de Educación*, 76(2):45–62, 2018. doi: 10.35362/rie7622948.
- Roger D. Peng. Reproducible research in computational science. *Science*, 334(6060):1226–1227, 2011.
- María Paz Prendes, María del Mar Sánchez-Vera, and Javier Serrano. Las tic en la educación: impacto en la sociedad y en el sistema educativo. *Revista de Educación a Distancia (RED)*, (32):39–58, 2012. URL <https://revistas.um.es/red/article/view/183271>.
- R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria, 2023. URL <https://www.R-project.org/>.
- Margarita Ramas, Manuel Cebrián, and Raquel Martínez. Las tecnologías de la información y la comunicación y su influencia en la transmisión del conocimiento científico. *Revista Iberoamericana de Educación a Distancia*, 18(2):45–62, 2015. doi: 10.5944/ried.18.2.13700.
- Francesco Ricci, Lior Rokach, and Bracha Shapira. *Recommender Systems Handbook*. Springer Science & Business Media, 2011.

- Richard M. Ryan and Edward L. Deci. Self-determination theory and the facilitation of intrinsic motivation, social development, and well-being. *American Psychologist*, 55(1):68–78, 2000. doi: 10.1037/0003-066X.55.1.68.
- S. S. Shapiro and M. B. Wilk. An analysis of variance test for normality (complete samples). *Biometrika*, 52(3–4):591–611, 1965. doi: 10.1093/biomet/52.3-4.591.
- Javier Suárez Caballero. La gamificación y las tecnologías digitales en el área de matemáticas de educación primaria. *REDIMAT: Journal of Research in Mathematics Education*, 12(2): 225–248, 2023. doi: 10.17583/redimat.9617.
- C. Tolentino-Veliz, P. Bravo-Huivin, and G. Cieza-Mostacero. Revisión sistemática: Gamificación en aplicaciones móviles para la educación. *Revista Ibérica de Sistemas e Tecnologías de Informação*, E69:912–926, 2023. ISSN 1646-9895.
- Thomas P. Vartanian. *Secondary data analysis*. Oxford University Press, 2010.
- Taiyun Wei and Viliam Simko. *corrplot: Visualization of a Correlation Matrix*, 2021. URL <https://github.com/taiyun/corrplot>. R package version 0.92.
- Kevin Werbach and Dan Hunter. *For the Win: How Game Thinking Can Revolutionize Your Business*. Wharton Digital Press, Philadelphia, 2012.
- Halbert White. A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, 48(4):817–838, 1980.
- Hadley Wickham. *stringr: Simple, Consistent Wrappers for Common String Operations*, 2023. URL <https://CRAN.R-project.org/package=stringr>. R package version 1.5.0.
- Hadley Wickham and Jennifer Bryan. *readxl: Read Excel Files*, 2023. URL <https://CRAN.R-project.org/package=readxl>. R package version 1.4.3.
- Hadley Wickham, Romain François, Lionel Henry, Kirill Müller, and Davis Vaughan. *dplyr: A Grammar of Data Manipulation*, 2023a. URL <https://CRAN.R-project.org/package=dplyr>. R package version 1.1.3.
- Hadley Wickham, Jim Hester, and Jennifer Bryan. *readr: Read Rectangular Text Data*, 2023b. URL <https://CRAN.R-project.org/package=readr>. R package version 2.1.4.
- Jeffrey M. Wooldridge. *Introductory econometrics: A modern approach*. Cengage Learning, 5 edition, 2012.
- Achim Zeileis. Object-oriented computation of sandwich estimators. *Journal of Statistical Software*, 16(9):1–16, 2006. doi: 10.18637/jss.v016.i09.
- Achim Zeileis and Torsten Hothorn. Diagnostic checking in regression relationships. *R News*, 2(3):7–10, 2002.

Apéndices



Código R Utilizado en el Análisis

Este apéndice recoge el script de R v. 4.3.1 empleado para la totalidad del análisis estadístico. El código está organizado en bloques que siguen la secuencia metodológica descrita en el Capítulo 3. La reproducibilidad exacta de los resultados está garantizada mediante la semilla fija `set.seed(42)` y la exportación de todas las tablas intermedias en formato `.xlsx`.

Código A.1: Carga de paquetes

```
1      paquetes <- c("readxl", "dplyr", "ggplot2", "corrplot",  
2      "car", "lmtest", "sandwich", "irr", "writexl", "boot")  
3      for (p in paquetes) {  
4          if (!require(p, character.only = TRUE,  
5          quietly = TRUE)) {  
6              install.packages(p, type = "binary")  
7              library(p, character.only = TRUE)  
8          }  
9      }  
10     Establecer el directorio de trabajo en la carpeta  
11     del proyecto  
12     Modificar esta ruta segun el entorno local del usuario  
13     setwd("RUTA_AL_DIRECTORIO_DE_DATOS")
```

Código A.2: Verificación de tamaños poblacionales por estrato

```
1      library(readr); library(dplyr)  
2  
3      raw <- read_csv("Google-Playstore.csv",  
4      col_types = cols(.default = "c"))  
5  
6      raw <- raw %>%  
7      filter(!is.na('App Name'), !is.na('App Id')) %>%  
8      mutate('Rating Count' = as.numeric('Rating Count'),
```



```

9      'Maximum Installs' = as.numeric('Maximum Installs')) %>%
10     filter('Rating Count' > 0) %>%
11     distinct('App Id', .keep_all = TRUE) %>%
12     filter(!is.na('Maximum Installs'), 'Maximum Installs' > 0)
13     %>%
14     filter(Category %in% c("Education", "Educational"))
15
16     K      <- c("math","matem","subtract","multiply",
17     "division","geometry","algebra","calculus")
18     patron <- paste(K, collapse = "|")
19     poblacion <- raw %>%
20     filter(grepl(patron, tolower('App Name')) %>%
21     mutate(LogMaxInstalls = log10('Maximum Installs' + 1))
22
23     Q25 <- quantile(poblacion$LogMaxInstalls, 0.25)
24     Q50 <- quantile(poblacion$LogMaxInstalls, 0.50)
25     Q75 <- quantile(poblacion$LogMaxInstalls, 0.75)
26
27     poblacion <- poblacion %>%
28     mutate(EstratoPopularidad = case_when(
29     LogMaxInstalls < Q25 ~ "Baja",
30     LogMaxInstalls < Q50 ~ "Media",
31     LogMaxInstalls < Q75 ~ "MediaAlta",
32     TRUE ~ "Alta"))
33
34     tam <- table(poblacion$EstratoPopularidad)
35     print(tam)          # Alta:1055 Baja:1055 Media:1054
36     MediaAlta:1054
37     print(tam / 50)     # Pesos de disenno w_h = N_h/n_h
38     (aprox. 21.09 en todos)
39     cat("Variacion_maxima_entre_pesos:",
40     round((max(tam/50) - min(tam/50)) / mean(tam/50) * 100,
41     3), "%\n")

```

Código A.3: Validacion empirica del filtro semantico K

```

1      K_original <- c("math","matem","subtract","multiply",
2      "division","geometry","algebra","calculus")
3      K_ampliado <- c("math","matem","subtract","multiply",
4      "division","geometry","algebra","calculus",
5      "arithmetic","fraction","number","addition",
6      "times_table","suma","resta","multiplicar",
7      "dividir","fraccion","numeros","count")
8
9      patron_original <- paste(K_original, collapse = "|")
10     patron_ampliado <- paste(K_ampliado, collapse = "|")
11     nombre_lower     <- tolower(raw$'App Name')
12
13     mask_original <- grepl(patron_original, nombre_lower)
14     mask_ampliado <- grepl(patron_ampliado, nombre_lower)
15     mask_nuevas    <- mask_ampliado & !mask_original
16
17     cat("K_original_\n->", sum(mask_original), "apps\n") # 4218
18     cat("K_ampliado_\n->", sum(mask_ampliado), "apps\n") # 5799

```

```

19         cat("Apps_nuevas:", sum(mask_nuevas), "\n")           # 1581
20
21         # Keywords que impulsan las nuevas capturas
22         K_nuevo <- c("arithmetic","fraction","number","addition",
23                     "times_table","suma","resta","multiplicar",
24                     "dividir","fraccion","numeros","count")
25         for (k in K_nuevo) {
26             apps_k <- raw[mask_nuevas, ]
27             n <- sum(grepl(k, tolower(apps_k$'App Name'))
28             cat(k, "->", n, "apps\n")
29         }
30
31         apps_nuevas <- raw[mask_nuevas, c("App_Name",
32                                           "Maximum_Installs","Rating")]
33         write_xlsx(as.data.frame(apps_nuevas),
34                   "apps_K_ampliado_revision.xlsx")

```

Código A.4: Kappa de Cohen

```

1  juez2 <- read_excel("codificacion_juez2.xlsx")
2  vars_kappa <- c("V_Niveles","V_Recompensas","V_Ranking",
3  "V_Avatares","V_Feedback")
4
5  # Cargar tus 30 apps codificadas (juez 1)
6  datos_kappa <- read_excel("muestra_200_CODIFICADA.xlsx",
7  sheet = "CODIFICACION")
8  set.seed(42)
9  indices_kappa <- sample(1:nrow(datos_kappa), 30, replace = FALSE)
10 juez1_vals <- datos_kappa[indices_kappa, vars_kappa]
11
12 # Calcular kappa por variable
13 resultados_kappa <- data.frame(
14   Variable = vars_kappa,
15   Kappa     = NA_real_,
16   Po       = NA_real_,
17   Interp   = NA_character_,
18   stringsAsFactors = FALSE
19 )
20
21 for (i in seq_along(vars_kappa)) {
22   v <- vars_kappa[i]
23   res <- kappa2(data.frame(as.numeric(juez1_vals[[v]]),
24                             as.numeric(juez2[[v]])))
25   k <- round(res$value, 3)
26   po <- round(res$agree, 3)
27   interp <- ifelse(k < 0.40, "Debil",
28                    ifelse(k < 0.60, "Moderado",
29                    ifelse(k < 0.80, "Sustancial", "Casi_perfecto")))
30   resultados_kappa$Kappa[i] <- k
31   resultados_kappa$Po[i] <- po
32   resultados_kappa$Interp[i] <- interp
33   cat(v, "->_kappa_=", k, "(", interp, ")\n")
34 }
35 cat("\nKappa_global_(media):",

```

```
36 round(mean(resultados_kappa$Kappa), 3), "\n")
37 write_xlsx(resultados_kappa, "tabla_kappa_resultados.xlsx")
```

Código A.5: Carga, transformación e imputación de datos

```
1  datos <- read_excel("muestra_200_RECONCILIADA.xlsx",
2                      sheet = "CODIFICACION")
3
4  datos <- datos %>%
5    mutate(
6      V_Niveles           = as.integer(V_Niveles),
7      V_Recompensas       = as.integer(V_Recompensas),
8      V_Ranking           = as.integer(V_Ranking),
9      V_Avatares          = as.integer(V_Avatares),
10     V_Feedback           = as.integer(V_Feedback),
11     Rating               = as.numeric(Rating),
12     'Rating Count'       = as.numeric('Rating Count'),
13     'Maximum Installs'   = as.numeric('Maximum Installs'),
14     Price                 = as.numeric(Price),
15     LogMaxInstalls       = as.numeric(LogMaxInstalls),
16     IAP_bin = ifelse(tolower(as.character(
17       'In App Purchases')) == "true", 1L, 0L),
18     ADS_bin = ifelse(tolower(as.character(
19       'Ad Supported')) == "true", 1L, 0L)
20   )
21
22 # Imputacion conservadora (criterio: ausencia = 0)
23 datos$V_Ranking[is.na(datos$V_Ranking)] <- 0L
24 datos$V_Recompensas[is.na(datos$V_Recompensas)] <- 0L
25
26 # Estimador bayesiano del rating
27 vi <- datos$'Rating Count'
28 Ri <- datos$Rating
29 C <- mean(Ri, na.rm = TRUE)
30 m0 <- quantile(vi, 0.75, na.rm = TRUE)
31 datos$Rating_Adj <- (vi / (vi + m0)) * Ri +
32                   (m0 / (vi + m0)) * C
33
34 # Indice compuesto de gamificacion
35 datos$IGam <- datos$V_Niveles + datos$V_Recompensas +
36               datos$V_Ranking + datos$V_Avatares +
37               datos$V_Feedback
```

Código A.6: Validación del umbral de regularización m_0

```
1  m0 <- quantile(datos$'Rating Count', 0.75, na.rm = TRUE)
2  cat("m0_=", m0, "\n")
3  cat("% apps con menos de m0 valoraciones:",
4      round(mean(datos$'Rating Count' < m0, na.rm = TRUE)
5            * 100, 1), "%\n")
```

Código A.7: Estadísticos descriptivos y prevalencia por estrato

```

1 vars_modelo <- c("LogMaxInstalls", "V_Niveles", "V_Recompensas",
2                 "V_Ranking", "V_Avatares", "V_Feedback",
3                 "Price", "Rating_Adj", "ADS_bin", "IAP_bin",
4                 "IGam")
5
6 desc <- data.frame(
7   Variable = vars_modelo,
8   Media     = sapply(vars_modelo,
9                       function(v) round(mean(datos[[v]], na.rm=TRUE), 3)),
10  Desv_Tip   = sapply(vars_modelo,
11                      function(v) round(sd(datos[[v]], na.rm=TRUE), 3)),
12  Min        = sapply(vars_modelo,
13                      function(v) round(min(datos[[v]], na.rm=TRUE), 3)),
14  Max        = sapply(vars_modelo,
15                      function(v) round(max(datos[[v]], na.rm=TRUE), 3))
16 )
17 write_xlsx(desc, "tabla_descriptivos.xlsx")
18
19 prev_estrato <- datos %>%
20   group_by(EstratoPopularidad) %>%
21   summarise(
22     n = n(),
23     pct_Niveles = round(mean(V_Niveles, na.rm=TRUE)*100, 1),
24     pct_Recomp = round(mean(V_Recompensas, na.rm=TRUE)*100, 1),
25     pct_Ranking = round(mean(V_Ranking, na.rm=TRUE)*100, 1),
26     pct_Avatares = round(mean(V_Avatares, na.rm=TRUE)*100, 1),
27     pct_Feedback = round(mean(V_Feedback, na.rm=TRUE)*100, 1),
28     pct_IAP = round(mean(IAP_bin, na.rm=TRUE)*100, 1),
29     IGam_media = round(mean(IGam, na.rm=TRUE), 2)
30   )
31 write_xlsx(prev_estrato, "tabla_prevalencia_estrato.xlsx")

```

Código A.8: Tests de independencia Mecanica por Estrato

```

1 vars_gam <- c("V_Niveles", "V_Recompensas", "V_Ranking",
2             "V_Avatares", "V_Feedback")
3
4 set.seed(42)
5 for (v in vars_gam) {
6   tbl <- table(datos$EstratoPopularidad,
7               datos[[v]])
8   esperadas <- chisq.test(tbl)$expected
9   if (any(esperadas < 5)) {
10     res <- fisher.test(tbl, simulate.p.value =
11                      TRUE, B = 10000)
12     cat(v, "-> Fisher exacto, p=", round(
13         res$p.value, 4), "\n")
14   } else {
15     res <- chisq.test(tbl)
16     cat(v, "-> chi2=", round(res$statistic,
17                             3),
18         ", p=", round(res$p.value, 4), "\n")
19   }
20 }

```

Código A.9: Matriz de correlaciones de Pearson

```

1 vars_cor <- c("LogMaxInstalls", "V_Niveles", "V_Recompensas",
2               "V_Ranking", "V_Avatares", "V_Feedback",
3               "Price", "Rating_Adj", "ADS_bin", "IAP_bin")
4
5 mat_cor <- cor(datos[, vars_cor],
6               use = "complete.obs", method = "pearson")
7
8 pdf("grafico_correlaciones.pdf", width=9, height=8)
9 corrplot(mat_cor,
10          method      = "color",
11          type         = "upper",
12          addCoef.col  = "black",
13          number.cex   = 0.7,
14          tl.col       = "black",
15          tl.srt        = 45,
16          title        = "Matriz de Correlaciones de Pearson",
17          mar          = c(0,0,2,0))
18 dev.off()

```

Código A.10: Estimación del Modelo I (MCO con errores robustos HC3)

```

1 modelo_I <- lm(LogMaxInstalls ~
2               V_Niveles + V_Recompensas + V_Ranking +
3               V_Avatares + V_Feedback +
4               Price + Rating_Adj + ADS_bin + IAP_bin,
5               data = datos)
6 summary(modelo_I)
7
8 # Errores robustos HC3
9 library(sandwich)
10 coeftest(modelo_I, vcov = vcovHC(modelo_I, type = "HC3"))

```

Código A.11: Test F de restricciones lineales (Modelo I vs. Modelo II)

```

1 # Test F robusto (HC3) Modelo I vs Modelo II
2 library(car)
3 linearHypothesis(modelo_I,
4 c("V_Niveles=V_Recompensas",
5   "V_Niveles=V_Ranking",
6   "V_Niveles=V_Avatares",
7   "V_Niveles=V_Feedback"),
8 vcov = vcovHC(modelo_I, type = "HC3"))

```

Código A.12: Estimación del Modelo II (índice compuesto IGam)

```

1 modelo_II <- lm(LogMaxInstalls ~
2               IGam + Price + Rating_Adj + ADS_bin + IAP_bin,
3               data = datos)
4 summary(modelo_II)
5

```

```

6 cat("R2_ajustado_Modelo_I:",
7     round(summary(modelo_I)$adj.r.squared, 4), "\n")
8 cat("R2_ajustado_Modelo_II:",
9     round(summary(modelo_II)$adj.r.squared, 4), "\n")

```

Código A.13: Diagnóstico del Modelo I: VIF, heterocedasticidad, normalidad y observaciones influyentes

```

1  # Multicolinealidad (VIF)
2  vif_vals <- vif(modelo_I)
3  print(round(vif_vals, 3))
4
5  # Heterocedasticidad (Breusch-Pagan)
6  bp_test <- bptest(modelo_I)
7  print(bp_test)
8
9  # Normalidad de residuos (Shapiro-Wilk)
10 sw_test <- shapiro.test(residuals(modelo_I))
11 print(sw_test)
12
13 # Grafico Q-Q
14 pdf("grafico_qq_residuos.pdf", width=6, height=6)
15 qqnorm(rstandard(modelo_I),
16        main = "Q-Q Plot - Residuos Estandarizados (Modelo I)",
17        xlab = "Cuantiles Teoricos",
18        ylab = "Cuantiles Muestrales",
19        pch = 16, col = "steelblue", cex = 0.7)
20 qqline(rstandard(modelo_I), col = "red", lwd = 1.5)
21 dev.off()
22
23 # Distancia de Cook
24 cook <- cooks.distance(modelo_I)
25 umbral <- 4 / nrow(datos)
26 cat("Observaciones influyentes:",
27     sum(cook > umbral), "\n")
28
29 pdf("grafico_cook.pdf", width=9, height=5)
30 plot(cook, type = "h",
31      col = ifelse(cook > umbral, "red", "steelblue"),
32      main = "Distancia de Cook por Observacion",
33      xlab = "Indice de Observacion",
34      ylab = "Distancia de Cook", lwd = 1.5)
35 abline(h = umbral, col = "red", lty = 2, lwd = 1.5)
36 legend("topright",
37      legend = c("Normal", "Influyente", "Umbral 4/n"),
38      col = c("steelblue", "red", "red"),
39      lty = c(1, 1, 2), lwd = 1.5)
40 dev.off()

```

Código A.14: Análisis de robustez del coeficiente de Recompensas

```

1  library(sandwich); library(lmtest); library(boot)
2

```

```

3      # 1. Modelo sin observaciones influyentes
4      cook <- cooks.distance(modelo_I)
5      umbral <- 4 / nrow(datos)
6      datos_sin_inf <- datos[cook <= umbral, ]
7      modelo_sin_inf <- lm(LogMaxInstalls ~ V_Niveles +
8      V_Recompensas
9      + V_Ranking + V_Avatares + V_Feedback +
10     Price + Rating_Adj + ADS_bin + IAP_bin,
11     data = datos_sin_inf)
12     coeftest(modelo_sin_inf, vcov = vcovHC(modelo_sin_inf,
13     type = "HC3"))
14     cat("R2_adj_sin_influyentes:",
15     round(summary(modelo_sin_inf)$adj.r.squared, 4), "\n")
16
17     # 2. Bootstrap (1.000 remuestras)
18     boot_fn <- function(data, indices) {
19         d <- data[indices, ]
20         m <- lm(LogMaxInstalls ~ V_Niveles + V_Recompensas
21         + V_Ranking + V_Avatares + V_Feedback + Price +
22         Rating_Adj + ADS_bin + IAP_bin, data = d)
23         coef(m)["V_Recompensas"]
24     }
25     set.seed(42)
26     boot_res <- boot(datos, boot_fn, R = 1000)
27     print(boot.ci(boot_res, type = c("perc", "bca")))
28
29     # 3. Fisher Estrato x Recompensas
30     tbl <- table(datos$EstratoPopularidad,
31     datos$V_Recompensas)
32     print(tbl)
33     fisher.test(tbl)

```

Código A.15: Test de equivalencia TOST para Niveles y Ranking

```

1      library(TOSTER)
2
3
4      ct <- coeftest(modelo_I, vcov = vcovHC(modelo_I,
5      type = "HC3"))
6
7      beta_niveles <- ct["V_Niveles", "Estimate"]
8      se_niveles <- ct["V_Niveles", "Std._Error"]
9      beta_ranking <- ct["V_Ranking", "Estimate"]
10     se_ranking <- ct["V_Ranking", "Std._Error"]
11
12     delta <- 0.3
13
14     tost_niveles <- tsum_TOST(
15     m1 = beta_niveles, sd1 = se_niveles * sqrt(200), n1 = 200,
16     hypothesis = "EQU",
17     low_eqbound = -delta, high_eqbound = delta,
18     alpha = 0.05, eqbound_type = "raw"
19     )
20

```

```

21     tost_ranking <- tsum_TOST(
22     m1 = beta_ranking, sd1 = se_ranking * sqrt(200), n1 = 200,
23     hypothesis = "EQU",
24     low_eqbound = -delta, high_eqbound = delta,
25     alpha = 0.05, eqbound_type = "raw"
26     )
27
28     print(tost_niveles)
29     print(tost_ranking)

```

Código A.16: Sensibilidad del estimador bayesiano segun m0

```

1     valores_m0 <- c(50, 75, 100, 130, 200, 300)
2     resultados_sens <- data.frame(
3     m0 = valores_m0, beta_rating = NA_real_, p_rating
4     = NA_real_,
5     beta_recompensas = NA_real_, p_recompensas = NA_real_,
6     beta_IAP = NA_real_, R2_adj = NA_real_)
7
8     vi <- datos$`Rating Count`
9     Ri <- datos$Rating
10    C <- mean(Ri, na.rm = TRUE)
11
12    for (i in seq_along(valores_m0)) {
13        m0_i <- valores_m0[i]
14        datos$Rating_Adj_i <- (vi/(vi+m0_i))*Ri +
15        (m0_i/(vi+m0_i))*C
16        m_i <- lm(LogMaxInstalls ~ V_Niveles +
17        V_Recompensas + V_Ranking +
18        V_Avatares + V_Feedback + Price + Rating_Adj_i +
19        ADS_bin + IAP_bin, data = datos)
20        ct <- coefest(m_i, vcov = vcovHC(m_i, type =
21        "HC3"))
22        resultados_sens$beta_rating[i] <- round(
23        ct["Rating_Adj_i", "Estimate"], 3)
24        resultados_sens$p_rating[i] <- round(
25        ct["Rating_Adj_i", "Pr(>|t|)"], 4)
26        resultados_sens$beta_recompensas[i] <- round(
27        ct["V_Recompensas", "Estimate"], 3)
28        resultados_sens$p_recompensas[i] <- round(
29        ct["V_Recompensas", "Pr(>|t|)"], 4)
30        resultados_sens$beta_IAP[i] <- round(
31        ct["IAP_bin", "Estimate"], 3)
32        resultados_sens$R2_adj[i] <- round(
33        summary(m_i)$adj.r.squared, 4)
34    }
35    print(resultados_sens)
36    write_xlsx(resultados_sens, "tabla_sensibilidad_m0.xlsx")

```